

Veri Toplama

- yfinance, investpy, quandl gibi kütüphaneler kullanılarak, 2005-01-01 tarihinden itibaren aylık getirilere sahip hisse senetleri ve sektör verileri toplanacak.
- Web scraping ile sektörlerin ve hisse senetlerinin listesi çekilecek.

```
#!/pip install yfinance
#!/pip install scipy==1.14.0
#!/pip install --upgrade tsfresh

# Veri Çekme ve İşleme
import yfinance as yf
import pandas as pd
import requests
from io import StringIO
import random

# Web Scraping
from bs4 import BeautifulSoup

# Veri Görselleştirme
import matplotlib.pyplot as plt
import numpy as np

%matplotlib inline

def fetch_sectors_names():
    url = "https://stockanalysis.com/stocks/industry/sectors/"
    response = requests.get(url)

    if response.status_code == 200:
        soup = BeautifulSoup(response.content, "html.parser")
        df=pd.read_html(StringIO(str(soup.find_all("table"))))[0]

    else:
        print(f"Error: Failed to fetch data from page {url}")

    return df

def fetch_industry_names():
    url = "https://stockanalysis.com/stocks/industry/all/"
    response = requests.get(url)

    if response.status_code == 200:
        soup = BeautifulSoup(response.content, "html.parser")
        df=pd.read_html(StringIO(str(soup.find_all("table"))))[0]

    else:
        print(f"Error: Failed to fetch data from page {url}")
```

```

return df

def fetch_data(sectors):
    url = f"https://stockanalysis.com/stocks/sector/{sectors}/"
    response = requests.get(url)

    if response.status_code == 200:
        soup = BeautifulSoup(response.content, "html.parser")
        df=pd.read_html(StringIO(str(soup.find_all("table"))))[0]
        df.drop(columns='No.', inplace=True)

    else:
        print(f"Error: Failed to fetch data from page {url}")

    return df

```

```

sectors=fetch_sectors_names()
indusrty=fetch_industry_names()

```

sectors

	Sector Name	Stocks	Market Cap	Div.	Yield	PE Ratio	\
0	Financials	1272	11.96T		0.17%	15.88	
1	Healthcare	1157	8,050.42B		0.51%	59.35	
2	Technology	769	21.51T		0.49%	45.77	
3	Industrials	661	5,902.02B		1.19%	29.37	
4	Consumer Discretionary	561	8,772.75B		0.75%	29.42	
5	Materials	266	2,035.83B		1.71%	27.95	
6	Real Estate	263	1,675.38B		3.78%	49.20	
7	Energy	251	3,613.08B		3.18%	13.25	
8	Communication Services	245	6,456.13B		1.46%	33.37	
9	Consumer Staples	242	4,229.57B		1.53%	29.62	
10	Utilities	109	1,642.05B		2.74%	21.42	

	Profit Margin	1D Change	1Y Change
0	19.97%	-0.56%	37.57%
1	3.19%	-0.64%	10.10%
2	14.62%	-1.02%	48.02%
3	7.25%	-0.60%	26.47%
4	6.51%	-2.14%	38.69%
5	6.33%	-1.00%	13.76%
6	9.51%	-0.40%	13.67%
7	8.18%	-0.05%	12.47%
8	11.59%	-1.02%	40.95%
9	4.90%	-0.38%	26.62%
10	10.62%	-0.22%	37.92%

```

# Çektiğim verileri, data klasörü içerisinde tutuyorum
#mkdir ../data/stock_sectors

```

```

fetch_data(sectors='energy').to_csv('../data/stock_sectors/energy.csv')

fetch_data(sectors='financials').to_csv('../data/stock_sectors/financials.csv')

fetch_data(sectors='healthcare').to_csv('../data/stock_sectors/healthcare.csv')

fetch_data(sectors='technology').to_csv('../data/stock_sectors/technology.csv')

fetch_data(sectors='utilities').to_csv('../data/stock_sectors/utilities.csv')

fetch_data(sectors='real-estate').to_csv('../data/stock_sectors/real-estate.csv')

fetch_data(sectors='materials').to_csv('../data/stock_sectors/materials.csv')

fetch_data(sectors='industrials').to_csv('../data/stock_sectors/industrials.csv')

fetch_data(sectors='consumer-staples').to_csv('../data/stock_sectors/consumer-staples.csv')

fetch_data(sectors='consumer-discretionary').to_csv('../data/stock_sectors/consumer-discretionary.csv')

fetch_data(sectors='communication-services').to_csv('../data/stock_sectors/communication-services.csv')

```

- Hangi sütunu baz alacağımı kararlaştırmak için sütun isimlerini yazdırdım
- ['Open'] sütununu baz alacağım

```

aapl_data = yf.download("AAPL")
print(aapl_data.columns)

[*****100%*****] 1 of 1 completed

MultiIndex([( 'Close', 'AAPL'),
              ( 'High', 'AAPL'),
              ( 'Low', 'AAPL'),
              ( 'Open', 'AAPL'),
              ('Volume', 'AAPL')],
            names=['Price', 'Ticker'])

aapl_data.head()

```

Price Ticker Date	Close AAPL	High AAPL	Low AAPL	Open AAPL	Volume AAPL
1980-12-12	0.098834	0.099264	0.098834	0.098834	469033600
1980-12-15	0.093678	0.094108	0.093678	0.094108	175884800
1980-12-16	0.086802	0.087232	0.086802	0.087232	105728000
1980-12-17	0.088951	0.089381	0.088951	0.088951	86441600
1980-12-18	0.091530	0.091959	0.091530	0.091530	73449600

```
financials = pd.read_csv('../data/stock_sectors/financials.csv')
healthcare = pd.read_csv('../data/stock_sectors/healthcare.csv')
technology = pd.read_csv('../data/stock_sectors/technology.csv')
```

Tarihsel Veri Filtreleme ve En Büyük Firmaları Seçme

- Rastgele seçim yapmadan önce 2005 öncesi verisi olan hisseleri otomatik filtreledim
- En büyük 3 endüstriden (Sağlık, Finans ve Teknoloji) rastgele 500 tane firma seçtim
- Burada herhangi bir işlem yapmama gerek kalmadı çünkü zaten önceden hem boş sütunları temizledim hem de bütün veriyi 2005 tarihinden sonrası için ayarladım, kısacası sadece rastgele olarak firma seçmek kaldı

```
# Geçerli semboller (NaN veya float olmayanları aldım)
```

```
technology_tickers =
technology['Symbol'].dropna().astype(str).tolist()
financials_tickers = financials['Symbol'].dropna().tolist()
healthcare_tickers = healthcare['Symbol'].dropna().tolist()
```

```
# Her bir kategoriden EN BÜYÜK 600 şirket seçtim
```

```
technology_biggest = technology_tickers[:600]
financials_biggest = financials_tickers[:600]
healthcare_biggest = healthcare_tickers[:600]
```

```
# Tüm şirketleri birleştirdim
```

```
all_biggest_tickers = technology_biggest + financials_biggest +
healthcare_biggest
```

```
len(all_biggest_tickers)
```

```
1800
```

```
import time
```

```
# Semboller için listeyi 250'lik parçalara böldüm ki veri çekmesi
kolay olsun
```

```

chunks = [all_biggest_tickers[i:i+250] for i in range(0,
len(all_biggest_tickers), 250)]

# Veriyi parça parça çektim
all_data = []
for chunk in chunks:
    try:
        data = yf.download(chunk, start='2005-01-01')
        all_data.append(data)
        time.sleep(15) # 15 saniye bekleme, API limitini aşmamak için
    except yf.download.YFRateLimitError:
        print("Rate limit exceeded. Retrying in 60 seconds...")
        time.sleep(60)

[*****100%*****] 250 of 250
completed
[*****100%*****] 250 of 250
completed
[*****100%*****] 250 of 250
completed

1 Failed download:
['BRK.B']: YFTzMissingError('$%ticker%: possibly delisted; no timezone
found')
[*****100%*****] 250 of 250
completed

1 Failed download:
['AGM.A']: YFTzMissingError('$%ticker%: possibly delisted; no timezone
found')
[*****100%*****] 250 of 250
completed

5 Failed downloads:
['TDAC']: YFPricesMissingError('$%ticker%: possibly delisted; no price
data found (1d 2005-01-01 -> 2025-02-12)')
['JACS.RT', 'CRD.B', 'KFII', 'CRD.A']: YFTzMissingError('$%ticker%:
possibly delisted; no timezone found')
[*****100%*****] 250 of 250
completed

1 Failed download:
['BIO.B']: YFPricesMissingError('$%ticker%: possibly delisted; no
price data found (1d 2005-01-01 -> 2025-02-12)')
[*****100%*****] 250 of 250
completed
[*****100%*****] 50 of 50 completed

tickers = technology['Symbol'].tolist()

```

```
# Verileri çek
data = yf.download(tickers, start='2005-01-01')
```

TypeError: expected string or bytes-like object, got 'float'.

- Bu hatayı aldığım için `yfinance.download()` fonksiyonu bir `float` değeri ile karşılaşıyor, fakat bu fonksiyon yalnızca `string` türündeki sembollerle çalışabilir. `technology[Symbol]` sütununda bazı `NaN` veya `float` değerleri mevcut. Bu nedenle hata veriyor
 - `NaN` değerlerini temizledim
 - Sadece `string` değerleri aldım
- Ekstra olarak
 - `YFRateLimitError('Too Many Requests. Rate limited. Try after a while.')` hatası nedeniyle aralıklı veri indirdim

```
# Sonuçları birleştir
final_data = pd.concat(all_data, axis=1)

# "Open" fiyatlarını al
data_open = final_data['Open']

# Günlük verileri aylığa çeviriyoruz.
data_open_monthly = data_open.resample('M').first()
```

```
# Sonuç
print(data_open_monthly.head())
```

Ticker	AAPL	ACIW	ACN	ADBE	ADI
ADP \					
Date					
2005-01-31	0.974731	6.696667	19.106171	31.493821	23.208159
21.876524					
2005-02-28	1.159356	7.026667	18.113641	28.444421	22.499747
21.432076					
2005-03-31	1.353911	7.833333	18.134912	31.023913	23.340560
21.209859					
2005-04-30	1.266639	7.760000	17.702448	33.910000	22.857036
22.277329					
2005-05-31	1.089689	6.980000	15.348742	29.870001	21.419059
21.528960					

Ticker	ADSK	AFRM	AI	AKAM	...	SCPH	SLN	SLRN
STXS THRD \								
Date					...			
2005-01-31	38.280256	NaN	NaN	13.00	...	NaN	NaN	NaN
91.240875	NaN							
2005-02-28	29.144969	NaN	NaN	13.10	...	NaN	NaN	NaN
86.678833	NaN							

2005-03-31	29.914572	NaN	NaN	11.01	...	NaN	NaN	NaN
86.678833	NaN							
2005-04-30	29.690001	NaN	NaN	12.72	...	NaN	NaN	NaN
71.350365	NaN							
2005-05-31	31.850000	NaN	NaN	11.96	...	NaN	NaN	NaN
64.598541	NaN							

Ticker	TLSI	UTMD	VOR	VXRT	ZYBT
Date					
2005-01-31	NaN	14.252260	NaN	867.110930	NaN
2005-02-28	NaN	12.933301	NaN	771.752428	NaN
2005-03-31	NaN	13.708426	NaN	759.906664	NaN
2005-04-30	NaN	13.306285	NaN	740.361116	NaN
2005-05-31	NaN	13.501401	NaN	647.963999	NaN

[5 rows x 1800 columns]

- 1800 şirket verisini küçük bir alan kaplaması için parquet veri tipinde sakladım ve gzip şekilden sıkıştırdım

```
data_open_monthly.to_parquet("../data/processed_data/
1800_company_data.gzip", compression="gzip")


data_open_monthly.columns

Index(['AAPL', 'ACIW', 'ACN', 'ADBE', 'ADI', 'ADP', 'ADSK', 'AFRM',
      'AI',
      'AKAM',
      ...,
      'SCPH', 'SLN', 'SLRN', 'STXS', 'THRD', 'TLSI', 'UTMD', 'VOR',
      'VXRT',
      'ZYBT'],
      dtype='object', name='Ticker', length=1800)

# Şirket isimlerini belirleyin
companies = ['VREX', 'XERS', 'ZBIO', 'ZIMV', 'TBPH']

# Veriyi sadece istenen şirketlere göre filtrele
data_open_monthly_filtered = data_open_monthly[companies]

data_open_monthly_filtered.plot(kind='line', figsize=(16,4), logy=True)
<Axes: xlabel='Date'>
```



Hangi Durumda Eksik Verileri Doldurmak Mantıklı?

1. **Az sayıda eksik değer varsa** (örneğin, %10-20 civarında)
 - `ffill().bfill()` yöntemi **önceki ve sonraki değerlere bağlı olarak makul bir dolgu** yapar.
 - Eğer bir şirketin birkaç ay verisi eksikse ama genel trend belliyse, doldurmak **makul bir tahmin sağlar**.
 - **Sonuç: Doğruluk korunur**, özellikle kısa vadeli analizlerde işe yarar.
2. **Şirketin ticareti kesintiye uğramışsa ama sonra devam etmişse**
 - **İlk veriler sıfır olmamalı** çünkü o dönemlerde şirket aktifti ama veriler eksikti.
 - `mean()` kullanımı **güvenli olabilir**, ancak trendi bozabilir.

Hangi Durumda Şirketleri Droplamak Mantıklı?

1. **%70-80 eksik veri varsa**
 - Aylık açılış fiyatları gibi **trend takibi gerektiren bir veride**, aşırı boşluklar **gerçekçi olmayan tahminlere** neden olur.
 - `ffill().bfill()` yapıldığında **ilk başta dümdüz bir çizgi olup sonra ani değişim olması**, aslında **tahmin edilen verinin hatalı olabileceğini** gösterir.
 - **Sonuç: Eğer bir şirketin verisi %70-80 eksikse, bu şirketi droplamak genellikle daha güvenlidir.**

Ne Yapmalısın?

Seçenek 1: Çok Eksik Olan Şirketleri Filtreleyerek Dropla

```
missing_ratio = data_open_monthly.isna().mean()
filtered_data = data_open_monthly.loc[:, missing_ratio < 0.3] #
%30'dan fazla eksik olanları dropla
```

- %70-80 eksik olanları tamamen çıkarırsın, geriye daha sağlam veriler kalır.

Seenek 2: Eksik Azsa Doldur (ffill + bfill)

```
filtered_data = filtered_data.ffill().bfill()
```

- Sadece az eksik olan řirketler iin doldurma yapılır, daha gvenilir sonu verir.

```
filtered_data =  
pd.read_parquet("../data/processed_data/1800_company_data.gzip")  
  
# Her stunun eksik veri oranını hesapla  
missing_ratio = data_open_monthly.isna().mean()  
  
# %40'tan fazla eksik veri olan stunları drop et  
filtered_data = data_open_monthly.loc[:, missing_ratio < 0.4]  
  
# Kalan verileri ffill ve bfill ile doldur  
filtered_data = filtered_data.ffill().bfill()  
  
# Sonucu gster  
print(filtered_data.head())
```

Ticker	AAPL	ACIW	ACN	ADBE	ADI
ADP \					
Date					
2005-01-31	0.974731	6.696667	19.106171	31.493821	23.208159
21.876524					
2005-02-28	1.159356	7.026667	18.113641	28.444421	22.499747
21.432076					
2005-03-31	1.353911	7.833333	18.134912	31.023913	23.340560
21.209859					
2005-04-30	1.266639	7.760000	17.702448	33.910000	22.857036
22.277329					
2005-05-31	1.089689	6.980000	15.348742	29.870001	21.419059
21.528960					


Ticker	ADSK	AKAM	AMAT	AMD	...	ZYXI
CATX CGEN \						
Date					...	
2005-01-31	38.280256	13.00	12.584156	22.110001	...	0.146753
53.5 5.01						
2005-02-28	29.144969	13.10	11.735455	15.900000	...	0.132078
53.5 6.22						
2005-03-31	29.914572	11.01	12.906074	17.629999	...	0.141861
53.5 4.73						
2005-04-30	29.690001	12.72	12.035424	16.309999	...	0.112511
53.5 4.10						
2005-05-31	31.850000	11.96	10.945289	14.210000	...	0.122294
53.5 3.79						

Ticker	INFU	LFCR	PHLT	PLX	STXS	UTMD	VXRT
Date							
2005-01-31	3.75	6.84	9.25	20.0	91.240875	14.252260	867.110930
2005-02-28	3.75	6.89	9.25	20.0	86.678833	12.933301	771.752428
2005-03-31	3.75	6.99	9.25	20.0	86.678833	13.708426	759.906664
2005-04-30	3.75	7.48	9.25	16.0	71.350365	13.306285	740.361116
2005-05-31	3.75	6.54	9.25	23.0	64.598541	13.501401	647.963999

[5 rows x 900 columns]

```
filtered_data['PLX'].plot(kind='line',figsize=(16,4),logy=True)
```

<Axes: xlabel='Date'>



Data'yı Long Formata Dönüştürme:

1. `data_open_monthly.reset_index()`
 - `long_data = filtered_data.reset_index().melt(id_vars='Date', var_name='Ticker', value_name='Open')` Bu satır, `filtered_data` verisini **uzun formata** dönüştürmek için pandas'ın `melt()` fonksiyonunu kullanır.
 - `filtered_data` bir pandas **Series** objesidir ve indeksi tarihlerdir (aylık bazda).
 - `reset_index()`, bu diziyi bir **DataFrame**'e çevirir.
 - **İndeks** (Date sütunu olarak) veriye eklenir.
 - Açılış fiyatları aynı sütunda kalır.
2. `.melt(id_vars='Date', var_name='Ticker', value_name='Open')`
 - `melt()` fonksiyonu, veriyi **geniş formattan uzun formata** dönüştürür.
 - `id_vars='Date'` → "Date" sütununu korur.
 - `var_name='Ticker'` → Önceden sütun başlıklarında olan hisse senedi kodlarını "Ticker" olarak adlandırır.
 - `value_name='Open'` → Açılış fiyatlarını "Open" sütununa taşır.

Dönüştürmeden Önce (Geniş Format)

Date	AAPL	MSFT	GOOG
2024-01-01	150	300	2800
2024-02-01	155	310	2900

Dönüştürdükten Sonra (Uzun Format)

Date	Ticker	Open
2024-01-01	AAPL	150
2024-01-01	MSFT	300
2024-01-01	GOOG	2800
2024-02-01	AAPL	155
2024-02-01	MSFT	310
2024-02-01	GOOG	2900

Neden Kullanılır?

- Uzun format, **gruplama, filtreleme ve görselleştirme** işlemleri için daha uygundur.
- **seaborn** veya **matplotlib** ile grafik çizmek için daha kullanışlıdır.
- **Diğer veri setleriyle birleştirme** işlemleri (örneğin, sektör bilgisi eklemek) daha kolay olur.
- Ben 2. ve 3. neden için kullanıyor olacağım

```
# Uzun formata çevirme
long_data = filtered_data.reset_index().melt(id_vars='Date',
var_name='Ticker', value_name='Open')

# Sektör bilgilerini ekleme
sector_map = {}
for ticker in financials_biggest:
    sector_map[ticker] = 'Financials'

for ticker in healthcare_biggest:
    sector_map[ticker] = 'Healthcare'

for ticker in technology_biggest:
    sector_map[ticker] = 'Technology'

long_data['Sector'] = long_data['Ticker'].map(sector_map)

long_data.head()
```

	Date	Ticker	Open	Sector
0	2005-01-31	AAPL	0.974731	Technology
1	2005-02-28	AAPL	1.159356	Technology
2	2005-03-31	AAPL	1.353911	Technology
3	2005-04-30	AAPL	1.266639	Technology
4	2005-05-31	AAPL	1.089689	Technology

```
# Datayı kayıt et
long_data.to_csv('../data/processed_data/combined_data.csv',
index=False)

long_formatted_data =
pd.read_csv('../data/processed_data/combined_data.csv')

meaningless_data_difference = long_formatted_data[
    (long_formatted_data["Ticker"].isin(["AAPL", "EYPT"])) &
    (long_formatted_data["Date"].between("2005-01-01", "2006-01-01"))
][["Date", "Ticker", "Open"]]

print(meaningless_data_difference)
```

	Date	Ticker	Open
0	2005-01-31	AAPL	0.974731
1	2005-02-28	AAPL	1.159356
2	2005-03-31	AAPL	1.353911
3	2005-04-30	AAPL	1.266639
4	2005-05-31	AAPL	1.089689
5	2005-06-30	AAPL	1.200433
6	2005-07-31	AAPL	1.108347
7	2005-08-31	AAPL	1.281084
8	2005-09-30	AAPL	1.414399
9	2005-10-31	AAPL	1.629870
10	2005-11-30	AAPL	1.722558
11	2005-12-31	AAPL	2.074954
206910	2005-01-31	EYPT	420.000000
206911	2005-02-28	EYPT	356.000000
206912	2005-03-31	EYPT	328.000000
206913	2005-04-30	EYPT	270.000000
206914	2005-05-31	EYPT	208.000000
206915	2005-06-30	EYPT	238.000000
206916	2005-07-31	EYPT	244.399994
206917	2005-08-31	EYPT	272.000000
206918	2005-09-30	EYPT	244.000000
206919	2005-10-31	EYPT	276.399994
206920	2005-11-30	EYPT	240.000000
206921	2005-12-31	EYPT	188.000000

Log Dönüşümü Uygulaması ve Nedenleri

Veri setinizde farklı ölçeklerde değerler gözlemlenmektedir. Örneğin, bazı Ticker'ların (ör. **AAPL**) değerleri 1 civarındayken, bazıları (ör. **EYPT**) 400 gibi yüksek değerlere sahip. Bu durum, modellerin öğrenme sürecinde farklı ölçekler arasında dengesizliğe yol açabilir.

Log Dönüşümünün Avantajları

- **Ölçek Dengeleme:**

Log dönüşümü, büyük değerlerin etkisini azaltarak tüm değerleri daha benzer bir

ölçeğe çeker. Bu, özellikle farklı büyüklükteki değişkenlerin (tickerların) analizinde faydalıdır.

- **Varyansın Stabilizasyonu:**
Log dönüşümü, veri dağılımındaki varyansı stabil hale getirerek aşırı uç değerlerin (outlier) etkisini hafifletebilir.
- **Dağılımın Normalleşmesi:**
Birçok durumda log dönüşümü, verinin sağa çarpık dağılımını (right-skewed) daha normal bir dağılıma yaklaştırır, bu da bazı makine öğrenmesi algoritmalarının performansını artırabilir.

Dikkat Edilmesi Gerekenler

- **Pozitif Değerler:**
Log dönüşümünü doğrudan uygulayabilmek için verilerinizin pozitif olması gerekir. Eğer bazı değerler 0 veya negatif ise, `log1p` (yani, $\log(1 + x)$) dönüşümü uygulanabilir.
- **Farklı Ölçekler:**
Her ticker için log dönüşümünü ayrı ayrı uygulamak daha mantıklı olabilir. Bu sayede, her bir zaman serisinin kendi dağılım özelliklerine göre dönüşüm yapılır.
- **Küçük Değerler:**
Değerlerin 1'in altında olması durumunda log dönüşümü negatif sonuçlar verecektir. Bu durum modelleme açısından problem oluşturmaz, ancak yorumlanması sırasında dikkatli olunmalıdır.

Sonuç

Eğer bazı değerler diğerlerine göre "mantıksız" ya da "ölçülemeyecek kadar farklı" görünüyorsa, **log dönüşümü uygulamak:**

- Büyük ölçekli değerlerin etkisini azaltır,
- Farklı tickerların değerlerini karşılaştırılabilir hale getirir,
- Makine öğrenmesi ve istatistiksel modellerde daha stabil sonuçlar elde etmenize yardımcı olur.

Bu nedenle, veri setinizdeki ölçek farklılıklarını gidermek ve istatistiksel özellikleri (örn. `tsfresh` ile çıkarılacak öznitelikler) daha tutarlı hale getirmek için log dönüşümü mantıklı bir adım olabilir.

```
long_formatted_data["Open_LOG"] =  
np.log1p(long_formatted_data["Open"])
```


*#Halihazırdaki Open sütununu güncellemek yerine yeni sütun açmak daha mantıklı
#çünkü bu kısmı tekrar tekrar çalıştırırsak Open değerleri sürekli değişiyor olacak.*

```
meaningless_data_difference = long_formatted_data[
    (long_formatted_data["Ticker"].isin(["AAPL", "EYPT"])) &
    (long_formatted_data["Date"].between("2005-01-01", "2006-01-01"))
][["Date", "Ticker", "Open_LOG"]]
```


```
print(meaningless_data_difference)
```

	Date	Ticker	Open_LOG
0	2005-01-31	AAPL	0.680432
1	2005-02-28	AAPL	0.769810
2	2005-03-31	AAPL	0.856078
3	2005-04-30	AAPL	0.818298
4	2005-05-31	AAPL	0.737015
5	2005-06-30	AAPL	0.788654
6	2005-07-31	AAPL	0.745904
7	2005-08-31	AAPL	0.824651
8	2005-09-30	AAPL	0.881450
9	2005-10-31	AAPL	0.966934
10	2005-11-30	AAPL	1.001572
11	2005-12-31	AAPL	1.123290
206910	2005-01-31	EYPT	6.042633
206911	2005-02-28	EYPT	5.877736
206912	2005-03-31	EYPT	5.796058
206913	2005-04-30	EYPT	5.602119
206914	2005-05-31	EYPT	5.342334
206915	2005-06-30	EYPT	5.476464
206916	2005-07-31	EYPT	5.502890
206917	2005-08-31	EYPT	5.609472
206918	2005-09-30	EYPT	5.501258
206919	2005-10-31	EYPT	5.625460
206920	2005-11-30	EYPT	5.484797
206921	2005-12-31	EYPT	5.241747

```
plt.hist(long_formatted_data["Open"], bins=50)
plt.title("Log Dönüştürülmemiş Open Değerleri Dağılımı")
plt.xlabel("Open")
plt.ylabel("Frekans")
plt.show()
```



```
plt.hist(long_formatted_data["Open_LOG"], bins=50)
plt.title("Log Dönüştürülmüş Open Değerleri Dağılımı")
plt.xlabel("Log(Open)")
plt.ylabel("Frekans")
plt.show()
```



- **Open Değerleri:** İlk histogramdaki $x=0$ 'daki çubuk muhtemelen veri kümesinde çok sayıda sıfır veya çok küçük değerler olduğunu gösterir. Bu, Açık sütununda çok sayıda sıfır veya sıfıra yakın değer varsa meydana gelebilir. Ancak önemli olan, x 'teki diğer sayıların çok büyük olmasıdır.
- **Open_LOG Değerleri:** Log dönüşümü (\log_{10}) değerleri daha eşit bir şekilde dağılmıştır ve aşırı uç değerlerin etkisini azaltılmıştır

```
long_formatted_data.to_csv('../data/processed_data/  
LOG_combined_data.csv', index=False)  
  
# Oluşturduğumuz tabloyu okuyalım  
combined_data =  
pd.read_csv('../data/processed_data/LOG_combined_data.csv')  
  
combined_data.head()
```

	Date	Ticker	Open	Sector	Open_LOG
0	2005-01-31	AAPL	0.974731	Technology	0.680432
1	2005-02-28	AAPL	1.159356	Technology	0.769810
2	2005-03-31	AAPL	1.353911	Technology	0.856078
3	2005-04-30	AAPL	1.266639	Technology	0.818298
4	2005-05-31	AAPL	1.089689	Technology	0.737015

- Data-type'larında hata var ve tsfresh kütüphanesi ile çalışamam
- Hatanın nedeni, Date sütunu type olarak object ancak datetime64 olması gerek

```
print(combined_data.dtypes)

Date          object
Ticker        object
Open          float64
Sector        object
Open_LOG      float64
dtype: object

# Date sütununu datetime64 formuna çevirdim
combined_data['Date'] = pd.to_datetime(combined_data['Date'])

print(combined_data.dtypes)

Date          datetime64[ns]
Ticker        object
Open          float64
Sector        object
Open_LOG      float64
dtype: object
```

Kategorik Değişkenlerle Çalışma

Kategorik veriler, sayısal olmayan ve genellikle kategorilere ayrılan verilerdir. Örneğin, bir şirketin faaliyet gösterdiği sektör gibi kategorik bilgiler, modelleme süreçlerinde sayısal verilere dönüştürülmelidir. Kategorik verileri sayısal hale getirmek için kullanılan yaygın yöntemler **One-Hot Encoding** ve **Label Encoding**'dir.

Sektör Verisi (Nominal Değişken)

Verimdeki **Sektör** bilgisi, **nominal** (isimsel) bir değişkendir. Yani, sektörler arasında **doğal bir sıralama** ya da **ağırlık** yoktur. Örneğin, bir şirketin teknoloji, finans veya sağlık sektöründe olması, diğer sektörlerle göre daha üstün ya da daha düşük bir değer taşımaz. Her bir sektör, sadece bir isimsel kategoriye ifade eder.

One-Hot Encoding

Nominal veriler için, **One-Hot Encoding** yöntemi genellikle tercih edilir. Bu yöntemde, her benzersiz kategori için ayrı bir sütun oluşturulur ve gözlemde o kategoriye ait olan değer **1** ile işaretlenirken, diğerleri **0** olarak kodlanır. Bu, modelin sektöre ait kategorileri sayısal verilere dönüştürmesine olanak tanır ve herhangi bir sıralama veya ağırlık ilişkisi oluşturmaz.

Örneğin, **Sektör** değişkeninde "Teknoloji", "Finans" ve "Sağlık" gibi kategoriler varsa, One-Hot Encoding ile şu şekilde bir dönüşüm yapılır:

Date	Ticker	Open	Sector	Sector_Teknoloji	Sector_Finans	Sector_Sağlık
2022-01-01	AAPL	150	Teknoloji	1	0	0
2022-01-02	TSLA	700	Finans	0	1	0
2022-01-03	PFE	40	Sağlık	0	0	1

Bu şekilde, her sektör için ayrı bir sütun eklenmiş olur ve her gözlem, o sektöre ait olan sütunda **1** değerini alırken, diğer sütunlarda **0** değerini alır. Bu, modelin sektörler arasında herhangi bir sıralama yapmamasını sağlar ve sektörel bilgiler daha doğru bir şekilde temsil edilmiş olur.

```
# One-hot encoding uygulama: 'Sector' sütununu dönüştürüyoruz.
combined_data_encoded = pd.get_dummies(combined_data,
columns=['Sector'])
```

```
print(combined_data_encoded.head())
```

```

      Date Ticker      Open  Open_LOG  Sector_Financials
Sector_Healthcare \
0 2005-01-31  AAPL  0.974731  0.680432                False
False
1 2005-02-28  AAPL  1.159356  0.769810                False
False
2 2005-03-31  AAPL  1.353911  0.856078                False
False
3 2005-04-30  AAPL  1.266639  0.818298                False
False
4 2005-05-31  AAPL  1.089689  0.737015                False
False

      Sector_Technology
0                    True
1                    True
2                    True
3                    True
4                    True

```

```
combined_data_encoded.to_csv('../data/processed_data/
encoded_combined_data.csv', index=False)
```

Öznitelik Çıkarımı ve Seçme

Öznitelik Çıkarımı:

tsfresh ile Otomatik Özellik Çıkarımı

Zaman serisi analizinde, veriden istatistiksel özellikler çıkarmak modelin başarısını artırabilir. **tsfresh** kütüphanesi, zaman serisi verilerinden otomatik olarak öznitelik (feature) çıkarımı yaparak analitik süreçleri hızlandırır. Bu süreçte çıkarılacak bazı temel istatistiksel özellikler şunlardır:

- **Ortalama (Mean):** Verinin genel eğilimini belirler.
- **Standart Sapma (Standard Deviation):** Verinin ne kadar değişkenlik gösterdiğini gösterir.
- **Otokorelasyon (Autocorrelation):** Bir zaman serisinin önceki değerleriyle olan ilişkisini ölçer.
- **Minimum ve Maksimum Değerler:** Veri setinin uç noktalarını belirler.
- **Medyan ve Çeyrek Değerler:** Veri dağılımı hakkında bilgi verir.

Ancak, **tsfresh** ile başarılı bir öznitelik çıkarımı için veri setinde eksik değer bulunmamalıdır. Eksik değerlerin doldurulması, sağlıklı analiz yapabilmek için kritik bir adımdır.

```
data_open_filled =
pd.read_csv('../data/processed_data/encoded_combined_data.csv')

data_open_filled.isna().sum()

Date                0
Ticker              0
Open               0
Open_LOG           0
Sector_Financials  0
Sector_Healthcare  0
Sector_Technology  0
dtype: int64

import tsfresh
from tsfresh.feature_extraction import EfficientFCParameters

# Extract features using only the 'Open' column
data_extract_features = tsfresh.extract_features(
    data_open_filled,
    column_id='Ticker',
    column_sort='Date',
    column_value='Open_LOG', # Explicitly specify the value column
    default_fc_parameters=EfficientFCParameters()
)

Feature Extraction: 100%|██████████| 30/30 [00:50<00:00, 1.68s/it]
```

```
data_extract_features.to_parquet('../data/processed_data/
extracted_features.parquet', compression='gzip')

data_extract_features.columns

Index(['Open_LOG__variance_larger_than_standard_deviation',
      'Open_LOG__has_duplicate_max', 'Open_LOG__has_duplicate_min',
      'Open_LOG__has_duplicate', 'Open_LOG__sum_values',
      'Open_LOG__abs_energy', 'Open_LOG__mean_abs_change',
      'Open_LOG__mean_change',
      'Open_LOG__mean_second_derivative_central',
      'Open_LOG__median',
      ...,
      'Open_LOG__fourier_entropy__bins_5',
      'Open_LOG__fourier_entropy__bins_10',
      'Open_LOG__fourier_entropy__bins_100',
      'Open_LOG__permutation_entropy__dimension_3__tau_1',
      'Open_LOG__permutation_entropy__dimension_4__tau_1',
      'Open_LOG__permutation_entropy__dimension_5__tau_1',
      'Open_LOG__permutation_entropy__dimension_6__tau_1',
      'Open_LOG__permutation_entropy__dimension_7__tau_1',
      'Open_LOG__query_similarity_count__query_None__threshold_0.0',
      'Open_LOG__mean_n_absolute_max__number_of_maxima_7'],
      dtype='object', length=777)
```

```
extracted_data =
pd.read_parquet('../data/processed_data/extracted_features.parquet')
```

```
extracted_data.head()
```

	Open_LOG__variance_larger_than_standard_deviation	\
A	0.0	
AAPL	1.0	
AB	0.0	
ABBV	0.0	
ABCB	0.0	

	Open_LOG__has_duplicate_max	Open_LOG__has_duplicate_min	\
A	0.0	0.0	
AAPL	0.0	0.0	
AB	0.0	0.0	
ABBV	0.0	1.0	
ABCB	0.0	0.0	

	Open_LOG__has_duplicate	Open_LOG__sum_values
Open_LOG__abs_energy	\	
A	0.0	913.803852
3586.251889		
AAPL	0.0	764.921929
2870.542166		
AB	0.0	657.495086

1859.250052

ABBV	1.0	916.311508
------	-----	------------

3591.156249

ABCB	0.0	753.473377
------	-----	------------

2445.777047

	Open_LOG__mean_abs_change	Open_LOG__mean_change \
A	0.063168	0.009434
AAPL	0.066749	0.019755
AB	0.062410	0.005599
ABBV	0.034470	0.008760
ABCB	0.073705	0.006244

	Open_LOG__mean_second_derivative_central	Open_LOG__median ...
\		
A	0.000388	3.640009 ...
AAPL	-0.000350	3.155702 ...
AB	-0.000013	2.678818 ...
ABBV	0.000071	3.666718 ...
ABCB	0.000179	3.136306 ...

	Open_LOG__fourier_entropy__bins_5
Open_LOG__fourier_entropy__bins_10 \	
A	0.047540
0.047540	
AAPL	0.047540
0.047540	
AB	0.095013
0.142417	
ABBV	0.047540
0.095013	
ABCB	0.095013
0.095013	

	Open_LOG__fourier_entropy__bins_100 \
A	0.210003
AAPL	0.210003
AB	0.426832
ABBV	0.225655
ABCB	0.238762

	Open_LOG__permutation_entropy__dimension_3__tau_1 \
A	1.703685
AAPL	1.606687
AB	1.699796

ABBV	1.268576
ABCB	1.736663
Open_LOG__permutation_entropy__dimension_4__tau_1 \	
A	2.868977
AAPL	2.710202
AB	2.881841
ABBV	2.090456
ABCB	2.972795
Open_LOG__permutation_entropy__dimension_5__tau_1 \	
A	3.985898
AAPL	3.765929
AB	3.992900
ABBV	2.826554
ABCB	4.162395
Open_LOG__permutation_entropy__dimension_6__tau_1 \	
A	4.740089
AAPL	4.525950
AB	4.705068
ABBV	3.266698
ABCB	4.969204
Open_LOG__permutation_entropy__dimension_7__tau_1 \	
A	5.092092
AAPL	4.966029
AB	5.026873
ABBV	3.559127
ABCB	5.265551
Open_LOG__query_similarity_count__query_None__threshold_0.0 \	
A	NaN
AAPL	NaN
AB	NaN
ABBV	NaN
ABCB	NaN
Open_LOG__mean_n_absolute_max__number_of_maxima_7	
A	5.053794
AAPL	5.445788
AB	3.700294
ABBV	5.239863
ABCB	4.162039

[5 rows x 777 columns]

Şirket Verilerine Endüstri Etiketi (Label) Eklenmesi

Neden Bu İşlemi Yaptık?

Elimizde 777 farklı şirketin piyasa açılış değerlerini içeren `extracted_data` adlı veri seti bulunmaktadır. Ancak, bu şirketlerin hangi sektöre ait olduğunu belirten bir sütun bulunmamaktadır. Bu bilgiyi eklemek, **makine öğrenmesi modellerinin** şirketlerin sektör bazlı analizlerini yapabilmesini sağlar.

Şirketlerin sektörel bilgileri, `combined_data_encoded` veri setinde **one-hot encoding** formatında bulunmaktadır. Bu veri setinde sektörler şu şekilde gösterilmektedir:

- `Sector_Technology` → **True** ise Teknoloji Sektörü
- `Sector_Financials` → **True** ise Finans Sektörü
- `Sector_Healthcare` → **True** ise Sağlık Sektörü

Bu bilgileri kullanarak her şirkete **0, 1 veya 2** olacak şekilde bir **Label** (etiket) sütunu ekledik:

- **0** → Teknoloji Şirketleri
- **1** → Finans Şirketleri
- **2** → Sağlık Şirketleri

Bu sayede `extracted_data` veri setimizde her şirketin ait olduğu sektörü belirten bir **Label** sütunu oluşturulmuş oldu.

Nasıl Yaptık?

1. Şirket-Sektör Bilgisini Çıkar

`combined_data_encoded` veri setinden her şirketin (Ticker) sektörünü belirledik:

```
# Şirketlerin sektörlerini içeren bir DataFrame oluştur
ticker_to_label = combined_data_encoded[['Ticker',
'Sector_Technology', 'Sector_Financials',
'Sector_Healthcare']].drop_duplicates()
```

2. Sektörleri 0, 1, 2 Olarak Kodla

Her sektör için aşağıdaki etiketleri atadık:

```
# Şirketlerin sektörlerini belirleyen fonksiyon
def get_sector_label(row):
    if row['Sector_Financials']:
        return 0 # Teknoloji
    elif row['Sector_Healthcare']:
        return 1 # Finans
    elif row['Sector_Technology']:
        return 2 # Sağlık
```

```
        return -1 # Hata kontrolü için

# Yeni Label sütununu ekledik
ticker_to_label['Label'] = ticker_to_label.apply(get_sector_label,
axis=1)

# Sadece farklı Ticker ve Label değerlerini al
ticker_to_label_unique = ticker_to_label[['Ticker',
'Label']].drop_duplicates()

# Eğer şirketler arasında tekrar varsa onları dropla
len(ticker_to_label_unique['Ticker'].unique())
```

3. Şirket İsimleri ile Label Eşleştirmesi Yap

extracted_data veri setinde bulunan **row, (index)** satırı, şirket isimlerini içeriyordu. Bu sütunu kullanarak sektör etiketlerini extracted_data içerisine ekledik:

```
# Şirket isimleri ile sektörleri eşleştirerek extracted_data'ya Label
sütununu ekleyelim
extracted_data = extracted_data.merge(ticker_to_label_unique,
left_index=True, right_on='Ticker', how='left')
```

4. Eksik Verileri Kontrol Et ve Gereksiz Sütunları Kaldır

Her şirket için bir etiket olup olmadığını kontrol ettik:

```
# Gereksiz fazlalıkları dropladım ve index kısmını resetledim
extracted_data = extracted_data.drop(['Label_x', 'Ticker'],
axis=1).reset_index(drop=True)
```

Sonuç

Bu işlemler sonucunda **extracted_data** veri setine **Label** sütunu eklendi. Bu sütun, her şirketin hangi sektöre ait olduğunu belirtiyor (**0 = Finans, 1 = Sağlık, 2 = Teknoloji**). Böylece, sektör bazlı analizler ve makine öğrenmesi modelleri için daha anlamlı bir veri seti elde edilmiş oldu.

```
combined_data_encoded =
pd.read_csv('../data/processed_data/encoded_combined_data.csv')

# Şirketlerin sektörlerini belirleyen fonksiyon
def get_sector_label(row):
    if row['Sector_Financials']:
        return 0 # Finans
    elif row['Sector_Healthcare']:
        return 1 # Sağlık
    elif row['Sector_Technology']:
```



```

        return 2 # Teknoloji
    return -1 # Hata kontrolü için

# Şirketlerin sektörlerini içeren bir DataFrame oluştur
ticker_to_label = combined_data_encoded[['Ticker',
'Sector_Financials', 'Sector_Healthcare',
'Sector_Technology']].drop_duplicates()

# Yeni Label sütunu ekle
ticker_to_label['Label'] = ticker_to_label.apply(get_sector_label,
axis=1)

# Sadece farklı Ticker ve Label değerlerini al
ticker_to_label_unique = ticker_to_label[['Ticker',
'Label']].drop_duplicates()

# Eğer şirketler arasında tekrar varsa onları dropla
len(ticker_to_label_unique['Ticker'].unique())

900

# Şirket isimleri ile sektörleri eşleştirerek extracted_data'ya Label
sütununu ekleyelim
extracted_data = extracted_data.merge(ticker_to_label_unique,
left_index=True, right_on='Ticker', how='left')

# Gereksiz fazlalıkları dropladım ve index kısmını resetledim
extracted_data = extracted_data.drop(['Ticker'],
axis=1).reset_index(drop=True)

# Eşleşmeyen şirketler olup olmadığını kontrol et (opsiyonel)
print(extracted_data['Label'].isna().sum(), "şirketin sektörü
bulunamadı.")

extracted_data.head()

0 şirketin sektörü bulunamadı.

```

	Open_LOG__variance_larger_than_standard_deviation \
0	0.0
1	1.0
2	0.0
3	0.0
4	0.0

	Open_LOG__has_duplicate_max	Open_LOG__has_duplicate_min \
0	0.0	0.0
1	0.0	0.0
2	0.0	0.0
3	0.0	1.0
4	0.0	0.0

	Open_LOG__has_duplicate	Open_LOG__sum_values	Open_LOG__abs_energy
\			
0	0.0	913.803852	3586.251889
1	0.0	764.921929	2870.542166
2	0.0	657.495086	1859.250052
3	1.0	916.311508	3591.156249
4	0.0	753.473377	2445.777047

	Open_LOG__mean_abs_change	Open_LOG__mean_change	\
0	0.063168	0.009434	
1	0.066749	0.019755	
2	0.062410	0.005599	
3	0.034470	0.008760	
4	0.073705	0.006244	

	Open_LOG__mean_second_derivative_central	Open_LOG__median	...	\
0	0.000388	3.640009	...	
1	-0.000350	3.155702	...	
2	-0.000013	2.678818	...	
3	0.000071	3.666718	...	
4	0.000179	3.136306	...	

	Open_LOG__fourier_entropy_bins_10	Open_LOG__fourier_entropy_bins_100	\
0	0.047540		
0.210003			
1	0.047540		
0.210003			
2	0.142417		
0.426832			
3	0.095013		
0.225655			
4	0.095013		
0.238762			

	Open_LOG__permutation_entropy_dimension_3_tau_1	\
0	1.703685	
1	1.606687	
2	1.699796	
3	1.268576	
4	1.736663	

	Open_LOG__permutation_entropy_dimension_4_tau_1	\
0	2.868977	

1	2.710202
2	2.881841
3	2.090456
4	2.972795

	Open_LOG__permutation_entropy_dimension_5_tau_1 \
0	3.985898
1	3.765929
2	3.992900
3	2.826554
4	4.162395

	Open_LOG__permutation_entropy_dimension_6_tau_1 \
0	4.740089
1	4.525950
2	4.705068
3	3.266698
4	4.969204

	Open_LOG__permutation_entropy_dimension_7_tau_1 \
0	5.092092
1	4.966029
2	5.026873
3	3.559127
4	5.265551

	Open_LOG__query_similarity_count__query_None__threshold_0.0 \
0	NaN
1	NaN
2	NaN
3	NaN
4	NaN

	Open_LOG__mean_n_absolute_max__number_of_maxima_7	Label
0	5.053794	1
1	5.445788	2
2	3.700294	0
3	5.239863	1
4	4.162039	0

[5 rows x 778 columns]

extracted_data.columns

```
Index(['Open_LOG__variance_larger_than_standard_deviation',
      'Open_LOG__has_duplicate_max', 'Open_LOG__has_duplicate_min',
      'Open_LOG__has_duplicate', 'Open_LOG__sum_values',
      'Open_LOG__abs_energy', 'Open_LOG__mean_abs_change',
      'Open_LOG__mean_change',
      'Open_LOG__mean_second_derivative_central',
```

```

        'Open_LOG__median',
        ...
        'Open_LOG__fourier_entropy__bins_10',
        'Open_LOG__fourier_entropy__bins_100',
        'Open_LOG__permutation_entropy__dimension_3__tau_1',
        'Open_LOG__permutation_entropy__dimension_4__tau_1',
        'Open_LOG__permutation_entropy__dimension_5__tau_1',
        'Open_LOG__permutation_entropy__dimension_6__tau_1',
        'Open_LOG__permutation_entropy__dimension_7__tau_1',
        'Open_LOG__query_similarity_count__query_None__threshold_0.0',
        'Open_LOG__mean_n_absolute_max__number_of_maxima_7', 'Label'],
        dtype='object', length=778)

# Boş değerler içeren sütunları bulalım
for col in extracted_data.columns:
    if extracted_data[col].isna().sum() > 0:
        print(f"Sütun ismi: {col}, boş değer sayısı: {extracted_data[col].isna().sum()}")

Sütun ismi: Open_LOG__friedrich_coefficients__coeff_0__m_3__r_30, boş
değer sayısı: 187
Sütun ismi: Open_LOG__friedrich_coefficients__coeff_1__m_3__r_30, boş
değer sayısı: 187
Sütun ismi: Open_LOG__friedrich_coefficients__coeff_2__m_3__r_30, boş
değer sayısı: 187
Sütun ismi: Open_LOG__friedrich_coefficients__coeff_3__m_3__r_30, boş
değer sayısı: 187
Sütun ismi: Open_LOG__max_langevin_fixed_point__m_3__r_30, boş değer
sayısı: 187
Sütun ismi:
Open_LOG__query_similarity_count__query_None__threshold_0.0, boş değer
sayısı: 900

# Drop empty columns
extracted_data = extracted_data.dropna(axis=1, how='any')

extracted_data['Label'].unique()

array([1, 2, 0], dtype=int64)

extracted_data.to_csv('../data/processed_data/
extracted_labeled_features.xlsx', index=False)

```

Öznitelik Seçme:

- Çıkarılan özellikler arasından en önemlileri seçmek için
 - L1 regularization (Lasso),
 - Recursive Feature Elimination (RFE)

RFE Sonuçları:

RFE, en önemli 385 özelliği seçmiştir. Aşağıda, Random Forest modeline göre sıralanan en önemli 20 özellik yer almaktadır:

1. ****Open_LOG__mean_abs_change****: 0.009998
2. ****Open_LOG__fft_coefficient__attr_"real"__coeff_7****: 0.009923
3. ****Open_LOG__fft_coefficient__attr_"angle"__coeff_58****: 0.008836
4. ****Open_LOG__sum_of_reoccurring_values****: 0.008206
5. ****Open_LOG__change_quantiles__f_agg_"mean"__isabs_True__qh_1.0__ql_0.8****: 0.008201

En önemli 20 özellik kullanılarak elde edilen doğruluk: 0.7167

Çapraz doğrulama skorları: [0.70833333, 0.70138889, 0.625, 0.69444444, 0.69444444]

Ortalama çapraz doğrulama skoru: 0.6847

L1 Sonuçları (Lasso):

Lasso (L1 regularization) ile 166 özellik arasından en önemli 20 özellik seçilmiştir. Aşağıda bu özellikler, Lasso katsayılarına göre sıralanmıştır:

1. ****Open_LOG__fft_coefficient__attr_"real"__coeff_44****: 2.795158
2. ****Open_LOG__fft_coefficient__attr_"real"__coeff_34****: 1.144467
3. ****Open_LOG__fft_coefficient__attr_"real"__coeff_18****: 0.940388
4. ****Open_LOG__fft_coefficient__attr_"real"__coeff_17****: 0.752983
5. ****Open_LOG__fft_coefficient__attr_"imag"__coeff_20****: 0.749958

En önemli 20 özellik kullanılarak elde edilen doğruluk (Lasso): 0.6944

Çapraz doğrulama skorları (Lasso): [0.72222222, 0.76388889, 0.75694444, 0.68055556, 0.72222222]

Ortalama çapraz doğrulama skoru (Lasso): 0.7292

Sonuçların Karşılaştırılması

- **RFE** yöntemi ile seçilen en önemli 20 özelliği kullanarak elde edilen doğruluk (0.7167) ve çapraz doğrulama skoru (0.6847), **Lasso** ile seçilen özellikler ile karşılaştırıldığında daha iyi bir performans göstermektedir.
- **Lasso** yönteminin doğruluk değeri 0.6944 ile biraz daha düşük olsa da, çapraz doğrulama skorları (0.7292) biraz daha yüksek olmuştur.
- Her iki yöntem de önemli özellikleri seçmiş ve farklı doğruluk değerleri elde edilmiştir, ancak genel olarak RFE ile elde edilen sonuçlar biraz daha başarılı olmuştur.

```
# Model ve Veri İşleme Araçları
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler, LabelEncoder
from sklearn.metrics import accuracy_score, classification_report

# Sınıflandırma Modelleri
from sklearn.ensemble import RandomForestClassifier,
GradientBoostingClassifier
```

```

from sklearn.linear_model import LogisticRegression
from sklearn.svm import SVC
from sklearn.neural_network import MLPClassifier

# Özellik Seçimi ve Boyut İndirgeme
from sklearn.feature_selection import RFE
from sklearn.decomposition import PCA

# Ekstra: XGBoost Modeli
from xgboost import XGBClassifier

# Veriyi yükle
extracted_labeled_data =
pd.read_csv('../data/processed_data/extracted_labeled_features.xlsx')

# Train ve Test için sütunları seç
X = extracted_labeled_data.drop(columns=['Label'])
y = extracted_labeled_data['Label']

# Train-test split
X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.2, random_state=0)

### 1. Recursive Feature Elimination (RFE) ###
selector_rfe = RFE(RandomForestClassifier(random_state=10))
selector_rfe.fit(X_train, y_train)

# Transform datasets
X_train_rfe = selector_rfe.transform(X_train)
X_test_rfe = selector_rfe.transform(X_test)

# Seçilen feature'ları yazdır
selected_features_rfe = X_train.columns[selector_rfe.get_support()]
print(f"RFE Selected Features ({len(selected_features_rfe)}):
{list(selected_features_rfe)}")

RFE Selected Features (385): ['Open_LOG__abs_energy',
'Open_LOG__mean_abs_change',
'Open_LOG__mean_second_derivative_central', 'Open_LOG__median',
'Open_LOG__variance', 'Open_LOG__skewness', 'Open_LOG__kurtosis',
'Open_LOG__absolute_sum_of_changes',
'Open_LOG__longest_strike_above_mean', 'Open_LOG__count_below_mean',
'Open_LOG__last_location_of_maximum',
'Open_LOG__first_location_of_maximum',
'Open_LOG__last_location_of_minimum',
'Open_LOG__percentage_of_reoccurring_values_to_all_values',
'Open_LOG__percentage_of_reoccurring_datapoints_to_all_datapoints',
'Open_LOG__sum_of_reoccurring_values',
'Open_LOG__sum_of_reoccurring_data_points', 'Open_LOG__c3__lag_1',
'Open_LOG__cid_ce_normalize_True',
'Open_LOG__cid_ce_normalize_False', 'Open_LOG__quantile__q_0.6',

```

```

'Open_LOG__quantile__q_0.7', 'Open_LOG__quantile__q_0.8',
'Open_LOG__quantile__q_0.9', 'Open_LOG__autocorrelation__lag_1',
'Open_LOG__autocorrelation__lag_2',
'Open_LOG__autocorrelation__lag_3',
'Open_LOG__autocorrelation__lag_4',
'Open_LOG__autocorrelation__lag_5',
'Open_LOG__autocorrelation__lag_6',
'Open_LOG__autocorrelation__lag_7',
'Open_LOG__autocorrelation__lag_8',
'Open_LOG__autocorrelation__lag_9',
'Open_LOG__agg_autocorrelation__f_agg_"mean"__maxlag_40',
'Open_LOG__agg_autocorrelation__f_agg_"median"__maxlag_40',
'Open_LOG__agg_autocorrelation__f_agg_"var"__maxlag_40',
'Open_LOG__partial_autocorrelation__lag_1',
'Open_LOG__partial_autocorrelation__lag_2',
'Open_LOG__partial_autocorrelation__lag_3',
'Open_LOG__partial_autocorrelation__lag_6',
'Open_LOG__partial_autocorrelation__lag_8',
'Open_LOG__partial_autocorrelation__lag_9',
'Open_LOG__cwt_coefficients__coeff_0__w_2__widths_(2, 5, 10, 20)',
'Open_LOG__cwt_coefficients__coeff_0__w_5__widths_(2, 5, 10, 20)',
'Open_LOG__cwt_coefficients__coeff_0__w_10__widths_(2, 5, 10, 20)',
'Open_LOG__cwt_coefficients__coeff_1__w_20__widths_(2, 5, 10, 20)',
'Open_LOG__cwt_coefficients__coeff_2__w_2__widths_(2, 5, 10, 20)',
'Open_LOG__cwt_coefficients__coeff_3__w_2__widths_(2, 5, 10, 20)',
'Open_LOG__cwt_coefficients__coeff_3__w_20__widths_(2, 5, 10, 20)',
'Open_LOG__cwt_coefficients__coeff_6__w_2__widths_(2, 5, 10, 20)',
'Open_LOG__cwt_coefficients__coeff_6__w_5__widths_(2, 5, 10, 20)',
'Open_LOG__cwt_coefficients__coeff_7__w_20__widths_(2, 5, 10, 20)',
'Open_LOG__cwt_coefficients__coeff_9__w_2__widths_(2, 5, 10, 20)',
'Open_LOG__cwt_coefficients__coeff_10__w_2__widths_(2, 5, 10, 20)',
'Open_LOG__cwt_coefficients__coeff_10__w_20__widths_(2, 5, 10, 20)',
'Open_LOG__cwt_coefficients__coeff_11__w_2__widths_(2, 5, 10, 20)',
'Open_LOG__cwt_coefficients__coeff_12__w_2__widths_(2, 5, 10, 20)',
'Open_LOG__cwt_coefficients__coeff_14__w_2__widths_(2, 5, 10, 20)',
'Open_LOG__cwt_coefficients__coeff_14__w_5__widths_(2, 5, 10, 20)',
'Open_LOG__spkt_welch_density__coeff_2',
'Open_LOG__spkt_welch_density__coeff_8',
'Open_LOG__ar_coefficient__coeff_1__k_10',
'Open_LOG__ar_coefficient__coeff_2__k_10',
'Open_LOG__ar_coefficient__coeff_3__k_10',
'Open_LOG__ar_coefficient__coeff_5__k_10',
'Open_LOG__ar_coefficient__coeff_6__k_10',
'Open_LOG__ar_coefficient__coeff_10__k_10',
'Open_LOG__change_quantiles__f_agg_"mean"__isabs_False__qh_0.2__ql_0.0',
',
'Open_LOG__change_quantiles__f_agg_"mean"__isabs_False__qh_0.4__ql_0.0',
',
'Open_LOG__change_quantiles__f_agg_"var"__isabs_False__qh_0.4__ql_0.0'

```

```
'Open_LOG__change_quantiles__f_agg_"mean"__isabs_True__qh_0.4__ql_0.0'  
,  
'Open_LOG__change_quantiles__f_agg_"var"__isabs_True__qh_0.4__ql_0.0',  
'Open_LOG__change_quantiles__f_agg_"var"__isabs_False__qh_0.6__ql_0.0'  
,  
'Open_LOG__change_quantiles__f_agg_"mean"__isabs_True__qh_0.6__ql_0.0'  
,  
'Open_LOG__change_quantiles__f_agg_"var"__isabs_True__qh_0.6__ql_0.0',  
'Open_LOG__change_quantiles__f_agg_"mean"__isabs_False__qh_0.8__ql_0.0'  
,  
,  
'Open_LOG__change_quantiles__f_agg_"var"__isabs_False__qh_0.8__ql_0.0'  
,  
'Open_LOG__change_quantiles__f_agg_"mean"__isabs_True__qh_0.8__ql_0.0'  
,  
'Open_LOG__change_quantiles__f_agg_"var"__isabs_True__qh_0.8__ql_0.0',  
'Open_LOG__change_quantiles__f_agg_"var"__isabs_False__qh_1.0__ql_0.0'  
,  
'Open_LOG__change_quantiles__f_agg_"mean"__isabs_True__qh_1.0__ql_0.0'  
,  
'Open_LOG__change_quantiles__f_agg_"var"__isabs_True__qh_1.0__ql_0.0',  
'Open_LOG__change_quantiles__f_agg_"var"__isabs_False__qh_0.4__ql_0.2'  
,  
'Open_LOG__change_quantiles__f_agg_"mean"__isabs_True__qh_0.4__ql_0.2'  
,  
'Open_LOG__change_quantiles__f_agg_"var"__isabs_True__qh_0.4__ql_0.2',  
'Open_LOG__change_quantiles__f_agg_"var"__isabs_False__qh_0.6__ql_0.2'  
,  
'Open_LOG__change_quantiles__f_agg_"var"__isabs_True__qh_0.6__ql_0.2',  
'Open_LOG__change_quantiles__f_agg_"mean"__isabs_False__qh_0.8__ql_0.2'  
,  
,  
'Open_LOG__change_quantiles__f_agg_"var"__isabs_False__qh_0.8__ql_0.2'  
,  
'Open_LOG__change_quantiles__f_agg_"mean"__isabs_True__qh_0.8__ql_0.2'  
,  
'Open_LOG__change_quantiles__f_agg_"var"__isabs_True__qh_0.8__ql_0.2',  
'Open_LOG__change_quantiles__f_agg_"var"__isabs_False__qh_1.0__ql_0.2'  
,  
'Open_LOG__change_quantiles__f_agg_"mean"__isabs_True__qh_1.0__ql_0.2'  
,  
'Open_LOG__change_quantiles__f_agg_"var"__isabs_True__qh_1.0__ql_0.2',  
'Open_LOG__change_quantiles__f_agg_"var"__isabs_False__qh_0.6__ql_0.4'  
,  
'Open_LOG__change_quantiles__f_agg_"mean"__isabs_True__qh_0.6__ql_0.4'  
,  
'Open_LOG__change_quantiles__f_agg_"var"__isabs_True__qh_0.6__ql_0.4',  
'Open_LOG__change_quantiles__f_agg_"mean"__isabs_False__qh_0.8__ql_0.4'  
,  
,  
'Open_LOG__change_quantiles__f_agg_"mean"__isabs_True__qh_0.8__ql_0.4'
```



```
'Open_LOG__change_quantiles__f_agg_"var"__isabs_False__qh_1.0__ql_0.4'
'Open_LOG__change_quantiles__f_agg_"mean"__isabs_True__qh_1.0__ql_0.4'
'Open_LOG__change_quantiles__f_agg_"var"__isabs_True__qh_1.0__ql_0.4',
'Open_LOG__change_quantiles__f_agg_"mean"__isabs_True__qh_0.8__ql_0.6'
'Open_LOG__change_quantiles__f_agg_"var"__isabs_False__qh_1.0__ql_0.6'
'Open_LOG__change_quantiles__f_agg_"mean"__isabs_True__qh_1.0__ql_0.6'
'Open_LOG__change_quantiles__f_agg_"var"__isabs_True__qh_1.0__ql_0.6',
'Open_LOG__change_quantiles__f_agg_"mean"__isabs_False__qh_1.0__ql_0.8'
,
'Open_LOG__change_quantiles__f_agg_"var"__isabs_False__qh_1.0__ql_0.8'
'Open_LOG__change_quantiles__f_agg_"mean"__isabs_True__qh_1.0__ql_0.8'
'Open_LOG__change_quantiles__f_agg_"var"__isabs_True__qh_1.0__ql_0.8',
'Open_LOG__fft_coefficient__attr_"real"__coeff_1',
'Open_LOG__fft_coefficient__attr_"real"__coeff_2',
'Open_LOG__fft_coefficient__attr_"real"__coeff_3',
'Open_LOG__fft_coefficient__attr_"real"__coeff_4',
'Open_LOG__fft_coefficient__attr_"real"__coeff_5',
'Open_LOG__fft_coefficient__attr_"real"__coeff_7',
'Open_LOG__fft_coefficient__attr_"real"__coeff_8',
'Open_LOG__fft_coefficient__attr_"real"__coeff_9',
'Open_LOG__fft_coefficient__attr_"real"__coeff_11',
'Open_LOG__fft_coefficient__attr_"real"__coeff_12',
'Open_LOG__fft_coefficient__attr_"real"__coeff_13',
'Open_LOG__fft_coefficient__attr_"real"__coeff_14',
'Open_LOG__fft_coefficient__attr_"real"__coeff_15',
'Open_LOG__fft_coefficient__attr_"real"__coeff_16',
'Open_LOG__fft_coefficient__attr_"real"__coeff_17',
'Open_LOG__fft_coefficient__attr_"real"__coeff_18',
'Open_LOG__fft_coefficient__attr_"real"__coeff_19',
'Open_LOG__fft_coefficient__attr_"real"__coeff_20',
'Open_LOG__fft_coefficient__attr_"real"__coeff_21',
'Open_LOG__fft_coefficient__attr_"real"__coeff_22',
'Open_LOG__fft_coefficient__attr_"real"__coeff_23',
'Open_LOG__fft_coefficient__attr_"real"__coeff_24',
'Open_LOG__fft_coefficient__attr_"real"__coeff_25',
'Open_LOG__fft_coefficient__attr_"real"__coeff_26',
'Open_LOG__fft_coefficient__attr_"real"__coeff_27',
'Open_LOG__fft_coefficient__attr_"real"__coeff_28',
'Open_LOG__fft_coefficient__attr_"real"__coeff_29',
'Open_LOG__fft_coefficient__attr_"real"__coeff_30',
'Open_LOG__fft_coefficient__attr_"real"__coeff_31',
```

[illegible]

[illegible]

[illegible]

[illegible]

```

'Open_LOG_fft_coefficient_attr_"angle"_coeff_72',
'Open_LOG_fft_coefficient_attr_"angle"_coeff_73',
'Open_LOG_fft_coefficient_attr_"angle"_coeff_74',
'Open_LOG_fft_coefficient_attr_"angle"_coeff_75',
'Open_LOG_fft_coefficient_attr_"angle"_coeff_77',
'Open_LOG_fft_coefficient_attr_"angle"_coeff_78',
'Open_LOG_fft_coefficient_attr_"angle"_coeff_81',
'Open_LOG_fft_coefficient_attr_"angle"_coeff_82',
'Open_LOG_fft_coefficient_attr_"angle"_coeff_83',
'Open_LOG_fft_coefficient_attr_"angle"_coeff_84',
'Open_LOG_fft_coefficient_attr_"angle"_coeff_87',
'Open_LOG_fft_coefficient_attr_"angle"_coeff_88',
'Open_LOG_fft_coefficient_attr_"angle"_coeff_89',
'Open_LOG_fft_coefficient_attr_"angle"_coeff_90',
'Open_LOG_fft_coefficient_attr_"angle"_coeff_91',
'Open_LOG_fft_coefficient_attr_"angle"_coeff_93',
'Open_LOG_fft_coefficient_attr_"angle"_coeff_94',
'Open_LOG_fft_coefficient_attr_"angle"_coeff_95',
'Open_LOG_fft_coefficient_attr_"angle"_coeff_96',
'Open_LOG_fft_coefficient_attr_"angle"_coeff_97',
'Open_LOG_fft_coefficient_attr_"angle"_coeff_99',
'Open_LOG_fft_aggregated_aggtype_"centroid"',
'Open_LOG_fft_aggregated_aggtype_"variance"',
'Open_LOG_fft_aggregated_aggtype_"skew"',
'Open_LOG_fft_aggregated_aggtype_"kurtosis"',
'Open_LOG_linear_trend_attr_"slope"',
'Open_LOG_linear_trend_attr_"stderr"',
'Open_LOG_agg_linear_trend_attr_"rvalue"__chunk_len_5__f_agg_"var"',
'Open_LOG_agg_linear_trend_attr_"rvalue"__chunk_len_10__f_agg_"var"',
',
'Open_LOG_agg_linear_trend_attr_"intercept"__chunk_len_5__f_agg_"max"',
',
'Open_LOG_agg_linear_trend_attr_"intercept"__chunk_len_10__f_agg_"mean"',
',
'Open_LOG_agg_linear_trend_attr_"intercept"__chunk_len_50__f_agg_"min"',
',
'Open_LOG_agg_linear_trend_attr_"slope"__chunk_len_5__f_agg_"var"',
'Open_LOG_agg_linear_trend_attr_"slope"__chunk_len_50__f_agg_"var"',
'Open_LOG_agg_linear_trend_attr_"stderr"__chunk_len_5__f_agg_"var"',
'Open_LOG_agg_linear_trend_attr_"stderr"__chunk_len_10__f_agg_"min"',
',
'Open_LOG_agg_linear_trend_attr_"stderr"__chunk_len_10__f_agg_"mean"',
',
'Open_LOG_agg_linear_trend_attr_"stderr"__chunk_len_50__f_agg_"min"',
',
'Open_LOG_agg_linear_trend_attr_"stderr"__chunk_len_50__f_agg_"mean"',
',
'Open_LOG_agg_linear_trend_attr_"stderr"__chunk_len_50__f_agg_"var"',
',

```

```
'Open_LOG__energy_ratio_by_chunks__num_segments_10__segment_focus_4',
'Open_LOG__energy_ratio_by_chunks__num_segments_10__segment_focus_5',
'Open_LOG__energy_ratio_by_chunks__num_segments_10__segment_focus_6',
'Open_LOG__energy_ratio_by_chunks__num_segments_10__segment_focus_7',
'Open_LOG__energy_ratio_by_chunks__num_segments_10__segment_focus_9',
'Open_LOG__ratio_beyond_r_sigma__r_0.5',
'Open_LOG__permutation_entropy_dimension_3__tau_1',
'Open_LOG__permutation_entropy_dimension_5__tau_1',
'Open_LOG__permutation_entropy_dimension_6__tau_1',
'Open_LOG__mean_n_absolute_max_number_of_maxima_7']
```

RFE'nin seçtiği feature'ları scores sütununa göre listele

```
results = pd.DataFrame(
    data=selector_rfe.estimator_.feature_importances_,
    index=selected_features_rfe,
    columns=['scores']
)
```

- Çıkardığım 385 feature'ın hepsini kullanarak model eğitirsem ortalama 0.73 accuracy alıyordum
- Aynı şekilde en iyi 20 feature'ı seçip model eğitirsem ortalama 0.71 accuracy alıyorum.
- Daha az feature ile aynı oranda doğruluk aldığım için en iyi 20 feature'ı seçtim

```
from sklearn.model_selection import cross_val_score
from sklearn.metrics import accuracy_score
```

Sonuçları büyükten küçüğe sırala

```
sorted_results_desc = results.sort_values(by='scores',
ascending=False)
```

En önemli 20 feature'ı seç

```
top_20_features_rf = sorted_results_desc.index[:20]
```

```
print(f"En önemli 20 feature (Random Forest önem değerlerine göre):")
for i, feature in enumerate(top_20_features_rf, 1):
    score = sorted_results_desc.loc[feature, 'scores']
    print(f"{i}. {feature}: {score:.6f}")
```

En önemli 20 feature (Random Forest önem değerlerine göre):

1. Open_LOG__mean_abs_change: 0.009998
2. Open_LOG__fft_coefficient__attr_"real"__coeff_7: 0.009923
3. Open_LOG__fft_coefficient__attr_"angle"__coeff_58: 0.008836
4. Open_LOG__sum_of_reoccurring_values: 0.008206
5. Open_LOG__change_quantiles__f_agg_"mean"__isabs_True__qh_1.0__ql_0.8: 0.008201
6. Open_LOG__change_quantiles__f_agg_"mean"__isabs_True__qh_1.0__ql_0.2: 0.007394
7. Open_LOG__fft_coefficient__attr_"real"__coeff_94: 0.007320

```

8. Open_LOG__fft_coefficient__attr_"real"__coeff_34: 0.007298
9.
Open_LOG__change_quantiles__f_agg_"mean"__isabs_True__qh_1.0__ql_0.0:
0.007214
10. Open_LOG__percentage_of_reoccurring_values_to_all_values: 0.007091
11.
Open_LOG__change_quantiles__f_agg_"mean"__isabs_True__qh_1.0__ql_0.6:
0.007058
12.
Open_LOG__change_quantiles__f_agg_"var"__isabs_False__qh_1.0__ql_0.4:
0.006988
13. Open_LOG__fft_coefficient__attr_"real"__coeff_11: 0.006836
14. Open_LOG__fft_coefficient__attr_"real"__coeff_90: 0.006485
15.
Open_LOG__change_quantiles__f_agg_"mean"__isabs_True__qh_1.0__ql_0.4:
0.006401
16. Open_LOG__absolute_sum_of_changes: 0.006284
17. Open_LOG__fft_coefficient__attr_"imag"__coeff_73: 0.006101
18. Open_LOG__fft_coefficient__attr_"real"__coeff_44: 0.005971
19. Open_LOG__fft_coefficient__attr_"imag"__coeff_97: 0.005838
20.
Open_LOG__change_quantiles__f_agg_"var"__isabs_False__qh_1.0__ql_0.6:
0.005837

```

Bu feature'ları kullanarak yeni veri setleri oluşturun

```
X_train_top20_rf = X_train[top_20_features_rf]
```

```
X_test_top20_rf = X_test[top_20_features_rf]
```

Model oluşturun ve eğit

```
rf_model_top20 = RandomForestClassifier(random_state=10)
```

```
rf_model_top20.fit(X_train_top20_rf, y_train)
```

Test seti üzerinde tahmin yap

```
y_pred_top20_rf = rf_model_top20.predict(X_test_top20_rf)
```

2. L1 Regularization (Lasso)

```
lasso = LogisticRegression(penalty="l1", solver="liblinear",
random_state=10)
```

```
lasso.fit(X_train, y_train)
```

NaN veya 0 olmayan feature'ları, Lasso ile seç

```
selected_features_lasso = X_train.columns[lasso.coef_[0] != 0]
```

```
X_train_lasso = X_train[selected_features_lasso]
```

```
X_test_lasso = X_test[selected_features_lasso]
```

```
print(f"Lasso Selected Features ({len(selected_features_lasso)}):
{list(selected_features_lasso)}")
```

```
Lasso Selected Features (166): ['Open_LOG__sum_values',
'Open_LOG__abs_energy', 'Open_LOG__length',
```



```
'Open_LOG__longest_strike_above_mean', 'Open_LOG__count_above_mean',  
'Open_LOG__count_below_mean', 'Open_LOG__sum_of_reoccurring_values',  
'Open_LOG__sum_of_reoccurring_data_points', 'Open_LOG__c3__lag_1',  
'Open_LOG__c3__lag_2', 'Open_LOG__c3__lag_3',  
'Open_LOG__number_cwt_peaks__n_1', 'Open_LOG__number_cwt_peaks__n_5',  
'Open_LOG__number_peaks__n_1', 'Open_LOG__number_peaks__n_3',  
'Open_LOG__number_peaks__n_10',  
'Open_LOG__spkt_welch_density__coeff_2',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_0',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_1',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_2',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_3',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_4',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_5',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_7',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_8',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_10',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_11',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_13',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_14',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_16',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_17',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_18',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_20',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_21',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_24',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_27',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_28',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_30',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_34',  
'Open_LOG__fft_coefficient__attr_"real"__coeff_44',  
'Open_LOG__fft_coefficient__attr_"imag"__coeff_1',  
'Open_LOG__fft_coefficient__attr_"imag"__coeff_2',  
'Open_LOG__fft_coefficient__attr_"imag"__coeff_3',  
'Open_LOG__fft_coefficient__attr_"imag"__coeff_4',  
'Open_LOG__fft_coefficient__attr_"imag"__coeff_5',  
'Open_LOG__fft_coefficient__attr_"imag"__coeff_6',  
'Open_LOG__fft_coefficient__attr_"imag"__coeff_7',  
'Open_LOG__fft_coefficient__attr_"imag"__coeff_8',  
'Open_LOG__fft_coefficient__attr_"imag"__coeff_9',  
'Open_LOG__fft_coefficient__attr_"imag"__coeff_11',  
'Open_LOG__fft_coefficient__attr_"imag"__coeff_12',  
'Open_LOG__fft_coefficient__attr_"imag"__coeff_18',  
'Open_LOG__fft_coefficient__attr_"imag"__coeff_20',  
'Open_LOG__fft_coefficient__attr_"imag"__coeff_22',  
'Open_LOG__fft_coefficient__attr_"imag"__coeff_23',  
'Open_LOG__fft_coefficient__attr_"imag"__coeff_27',  
'Open_LOG__fft_coefficient__attr_"imag"__coeff_34',  
'Open_LOG__fft_coefficient__attr_"abs"__coeff_0',
```

[illegible]

[illegible]

```
'Open_LOG_fft_coefficient_attr_"angle"__coeff_93',
'Open_LOG_fft_coefficient_attr_"angle"__coeff_94',
'Open_LOG_fft_coefficient_attr_"angle"__coeff_95',
'Open_LOG_fft_coefficient_attr_"angle"__coeff_96',
'Open_LOG_fft_coefficient_attr_"angle"__coeff_97',
'Open_LOG_fft_coefficient_attr_"angle"__coeff_98',
'Open_LOG_fft_coefficient_attr_"angle"__coeff_99',
'Open_LOG_fft_aggregated_aggtype_"variance"',
'Open_LOG_range_count_max_1_min_-1',
'Open_LOG_range_count_max_1000000000000.0_min_0']
```

2. L1 Regularization (Lasso) için özellik önem değerlerini hesaplayalım

L1 katsayılarının mutlak değerlerini alarak özellik önem sıralaması oluştur

```
feature_importance_lasso = pd.DataFrame({
    'scores': np.abs(lasso.coef_[0]),
    'names': X_train.columns
})
```

```
feature_importance_lasso = feature_importance_lasso.set_index('names')
```

Sonuçları büyükten küçüğe sırala

```
sorted_results_lasso_desc =
feature_importance_lasso.sort_values(by='scores', ascending=False)
```

En önemli 20 feature'ı seç

```
top_20_features_lasso = sorted_results_lasso_desc.index[:20]
print(f"En önemli 20 feature (Lasso katsayılarına göre):")
for i, feature in enumerate(top_20_features_lasso, 1):
    score = sorted_results_lasso_desc.loc[feature, 'scores']
    print(f"{i}. {feature}: {score:.6f}")
```

En önemli 20 feature (Lasso katsayılarına göre):

```
1. Open_LOG_fft_coefficient_attr_"real"__coeff_44: 2.795158
2. Open_LOG_fft_coefficient_attr_"real"__coeff_34: 1.144467
3. Open_LOG_fft_coefficient_attr_"real"__coeff_18: 0.940388
4. Open_LOG_fft_coefficient_attr_"real"__coeff_17: 0.752983
5. Open_LOG_fft_coefficient_attr_"imag"__coeff_20: 0.749958
6. Open_LOG_fft_coefficient_attr_"real"__coeff_24: 0.662814
7. Open_LOG_fft_coefficient_attr_"real"__coeff_20: 0.480475
8. Open_LOG_fft_coefficient_attr_"imag"__coeff_18: 0.461297
9. Open_LOG_fft_coefficient_attr_"abs"__coeff_25: 0.423871
10. Open_LOG_fft_coefficient_attr_"abs"__coeff_10: 0.419204
11. Open_LOG_fft_coefficient_attr_"imag"__coeff_8: 0.413403
12. Open_LOG_fft_coefficient_attr_"real"__coeff_16: 0.370956
13. Open_LOG_fft_coefficient_attr_"imag"__coeff_2: 0.338724
14. Open_LOG_fft_coefficient_attr_"real"__coeff_11: 0.326932
15. Open_LOG_fft_coefficient_attr_"imag"__coeff_27: 0.321631
16. Open_LOG_fft_coefficient_attr_"imag"__coeff_7: 0.301130
17. Open_LOG_fft_coefficient_attr_"abs"__coeff_24: 0.281229
```

```

18. Open_LOG_fft_coefficient_attr_"imag"__coeff_4: 0.277839
19. Open_LOG_fft_coefficient_attr_"real"__coeff_28: 0.274034
20. Open_LOG_fft_coefficient_attr_"real"__coeff_7: 0.271834

# Bu feature'ları kullanarak yeni veri setleri oluştur
X_train_top20_lasso = X_train[top_20_features_lasso]
X_test_top20_lasso = X_test[top_20_features_lasso]

# Model oluştur ve eğit (Lojistik Regresyon kullanıyoruz çünkü Lasso
bir özellik seçim yöntemidir)
lr_model_top20 = LogisticRegression(random_state=10)
lr_model_top20.fit(X_train_top20_lasso, y_train)

# Test seti üzerinde tahmin yap
y_pred_top20_lasso = lr_model_top20.predict(X_test_top20_lasso)

D:\Anaconda\Lib\site-packages\sklearn\linear_model\_logistic.py:460:
ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as
shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
https://scikit-learn.org/stable/modules/linear_model.html#logistic-
regression
    n_iter_i = _check_optimize_result(

# Doğruluk (accuracy) hesapla RFE
accuracy_top20_rf = accuracy_score(y_test, y_pred_top20_rf)
print(f"\nEn önemli 20 feature kullanılarak elde edilen doğruluk:
{accuracy_top20_rf:.4f}")

# Çapraz doğrulama yap RFE
cv_scores_top20_rf = cross_val_score(rf_model_top20, X_train_top20_rf,
y_train, cv=5, scoring='accuracy')
print(f"Çapraz doğrulama skorları: {cv_scores_top20_rf}")
print(f"Ortalama çapraz doğrulama skoru:
{cv_scores_top20_rf.mean():.4f}")

#-----

# Doğruluk (accuracy) hesapla Lasso
accuracy_top20_lasso = accuracy_score(y_test, y_pred_top20_lasso)
print(f"\nEn önemli 20 feature kullanılarak elde edilen doğruluk
(Lasso): {accuracy_top20_lasso:.4f}")

# Çapraz doğrulama yap Lasso
cv_scores_top20_lasso = cross_val_score(lr_model_top20,

```

```
X_train_top20_lasso, y_train, cv=5, scoring='accuracy')
print(f"Çapraz doğrulama skorları (Lasso): {cv_scores_top20_lasso}")
print(f"Ortalama çapraz doğrulama skoru (Lasso):
{cv_scores_top20_lasso.mean():.4f}")
```

En önemli 20 feature kullanılarak elde edilen doğruluk: 0.7167
Çapraz doğrulama skorları: [0.70833333 0.70138889 0.625
0.69444444 0.69444444]
Ortalama çapraz doğrulama skoru: 0.6847

En önemli 20 feature kullanılarak elde edilen doğruluk (Lasso): 0.6944
Çapraz doğrulama skorları (Lasso): [0.72222222 0.76388889 0.75694444
0.68055556 0.72222222]
Ortalama çapraz doğrulama skoru (Lasso): 0.7292

D:\Anaconda\Lib\site-packages\sklearn\linear_model_logistic.py:460:
ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as
shown in:

<https://scikit-learn.org/stable/modules/preprocessing.html>

Please also refer to the documentation for alternative solver options:

https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression

```
n_iter_i = _check_optimize_result(
D:\Anaconda\Lib\site-packages\sklearn\linear_model\_logistic.py:460:  
ConvergenceWarning: lbfgs failed to converge (status=1):  
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.
```

Increase the number of iterations (max_iter) or scale the data as
shown in:

<https://scikit-learn.org/stable/modules/preprocessing.html>

Please also refer to the documentation for alternative solver options:

https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression

```
n_iter_i = _check_optimize_result(
D:\Anaconda\Lib\site-packages\sklearn\linear_model\_logistic.py:460:  
ConvergenceWarning: lbfgs failed to converge (status=1):  
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.
```

Increase the number of iterations (max_iter) or scale the data as
shown in:

<https://scikit-learn.org/stable/modules/preprocessing.html>

Please also refer to the documentation for alternative solver options:

https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression

```
regression
    n_iter_i = _check_optimize_result(
D:\Anaconda\Lib\site-packages\sklearn\linear_model\_logistic.py:460:
ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.
```

Increase the number of iterations (max_iter) or scale the data as shown in:

<https://scikit-learn.org/stable/modules/preprocessing.html>

Please also refer to the documentation for alternative solver options:

https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression

```
    n_iter_i = _check_optimize_result(
D:\Anaconda\Lib\site-packages\sklearn\linear_model\_logistic.py:460:
ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.
```

Increase the number of iterations (max_iter) or scale the data as shown in:

<https://scikit-learn.org/stable/modules/preprocessing.html>

Please also refer to the documentation for alternative solver options:

https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression


```
    n_iter_i = _check_optimize_result(

# Feature importance values for RFE (Random Forest)
results_of_20_best_feature = pd.DataFrame(
    data=selector_rfe.estimator_.feature_importances_[ :20],
    index=selected_features_rfe[ :20],
    columns=['scores']
)
# Visualize importance scores
plt.figure(figsize=(14, 6))
results_of_20_best_feature.sort_values(by='scores',
ascending=False).plot.bar(
    title='Özellik Önem Skorları - RFE (Random Forest)'
)
plt.xlabel('Değişkenler')
plt.ylabel('RF Scores')
plt.xticks(rotation=90)
plt.tight_layout()
plt.show()
```

```
C:\Users\only\AppData\Local\Temp\ipykernel_8136\151639754.py:15:
UserWarning: Tight layout not applied. The bottom and top margins
cannot be made large enough to accommodate all axes decorations.
    plt.tight_layout()
```

<Figure size 1400x600 with 0 Axes>

Özellik Önem Skorları - RFE (Random Forest)



```

import os
import joblib # Modeli yüklemek için

# Kayıt dizinini oluştur (eğer yoksa)
save_dir = "../trained_models/"
os.makedirs(save_dir, exist_ok=True)

# Random Forest modelini kaydet
rf_model_path = os.path.join(save_dir, "rf_model_top20.pkl")
joblib.dump(rf_model_top20, rf_model_path)

# Logistic Regression modelini kaydet
lr_model_path = os.path.join(save_dir, "lr_model_top20_lasso.pkl")
joblib.dump(lr_model_top20, lr_model_path)

print(f"Modeller şu dizine kaydedildi: {save_dir}")

Modeller şu dizine kaydedildi: ../trained_models/

```

Model Geliştirme

```

# Gerekli kütüphaneleri içe aktaralım
from sklearn.linear_model import LogisticRegression
from sklearn.svm import SVC
from sklearn.ensemble import RandomForestClassifier,
GradientBoostingClassifier, AdaBoostClassifier
from sklearn.neural_network import MLPClassifier
from xgboost import XGBClassifier
from sklearn.linear_model import RidgeClassifier
from sklearn.neighbors import KNeighborsClassifier
from sklearn.naive_bayes import GaussianNB

# Label encoding (eğer label'lar string ise)
label_encoder = LabelEncoder()
y_train_encoded = label_encoder.fit_transform(y_train)
y_test_encoded = label_encoder.transform(y_test)

# Farklı modelleri tanımla
models = {
    # Temel modeller
    "Logistic Regression": LogisticRegression(max_iter=1000,
random_state=0),
    "SVC": SVC(random_state=0, probability=True),
    "Random Forest": RandomForestClassifier(n_estimators=100,
random_state=10),
    "Gradient Boosting": GradientBoostingClassifier(n_estimators=100,
random_state=10),

    # Gelişmiş modeller

```

```

    "XGBoost": XGBClassifier(n_estimators=100, random_state=10,
use_label_encoder=False, eval_metric='logloss'),
    "MLP Classifier": MLPClassifier(hidden_layer_sizes=(100, 50),
max_iter=1000, random_state=0),

    # Ek modeller
    "AdaBoost": AdaBoostClassifier(n_estimators=100, random_state=10),
    "Ridge Classifier": RidgeClassifier(random_state=0),
    "KNeighbors": KNeighborsClassifier(n_neighbors=5),
    "Gaussian NB": GaussianNB()
}

import os
import joblib # Modeli yüklemek için

# Kayıt dizinini oluştur (eğer yoksa)
save_dir = "../trained_models/"
os.makedirs(save_dir, exist_ok=True)

# Sonuçları tutacak liste
results = []

# Her modeli eğit, test et ve accuracy score hesapla
for model_name, model in models.items():
    print(f"\n{model_name} eğitiliyor...")
    model.fit(X_train_rfe, y_train_encoded) # Modeli eğit
    y_pred = model.predict(X_test_rfe) # Test verisiyle tahmin yap

    # Model dosya adını oluştur ve kaydet
    model_filename = os.path.join(save_dir, f"{model_name.replace(' ',
'_' )}.pkl")
    joblib.dump(model, model_filename) # Modeli kaydet
    print(f"{model_name} kaydedildi: {model_filename}")

    acc = accuracy_score(y_test_encoded, y_pred) # Accuracy hesapla
    print(f"{model_name} Accuracy: {acc:.4f}")

    target_names = [str(cls) for cls in label_encoder.classes_]
    # Classification report yazdır
    print(classification_report(y_test_encoded, y_pred,
target_names=target_names))

    # Sonuçları sakla
    results.append((model_name, acc))

# En iyi modeli bul
best_model = max(results, key=lambda x: x[1])
print(f"\nEn iyi model: {best_model[0]} (Accuracy:
{best_model[1]:.4f})")

```

Logistic Regression eğitiliyor...

D:\Anaconda\Lib\site-packages\sklearn\linear_model_logistic.py:460:
ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:

<https://scikit-learn.org/stable/modules/preprocessing.html>

Please also refer to the documentation for alternative solver options:

https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression

```
n_iter_i = _check_optimize_result(
```

Logistic Regression kaydedildi:

../trained_models/Logistic_Regression.pkl

Logistic Regression Accuracy: 0.7111

	precision	recall	f1-score	support
0	0.81	0.75	0.77	83
1	0.70	0.62	0.66	48
2	0.60	0.73	0.66	49
accuracy			0.71	180
macro avg	0.70	0.70	0.70	180
weighted avg	0.72	0.71	0.71	180

SVC eğitiliyor...

SVC kaydedildi: ../trained_models/SVC.pkl

SVC Accuracy: 0.5944

	precision	recall	f1-score	support
0	0.68	0.77	0.72	83
1	0.57	0.25	0.35	48
2	0.48	0.63	0.54	49
accuracy			0.59	180
macro avg	0.58	0.55	0.54	180
weighted avg	0.60	0.59	0.57	180

Random Forest eğitiliyor...

Random Forest kaydedildi: ../trained_models/Random_Forest.pkl

Random Forest Accuracy: 0.7556

	precision	recall	f1-score	support
0	0.86	0.82	0.84	83
1	0.81	0.62	0.71	48

2	0.59	0.78	0.67	49
accuracy			0.76	180
macro avg	0.76	0.74	0.74	180
weighted avg	0.77	0.76	0.76	180

Gradient Boosting eğitiliyor...

Gradient Boosting kaydedildi: ../trained_models/Gradient_Boosting.pkl

Gradient Boosting Accuracy: 0.8167

	precision	recall	f1-score	support
0	0.89	0.87	0.88	83
1	0.81	0.79	0.80	48
2	0.71	0.76	0.73	49
accuracy			0.82	180
macro avg	0.80	0.80	0.80	180
weighted avg	0.82	0.82	0.82	180

XGBoost eğitiliyor...

D:\Anaconda\Lib\site-packages\xgboost\core.py:158: UserWarning:
[16:09:26] WARNING: C:\buildkite-agent\builds\buildkite-windows-cpu-autoscaling-group-i-08cbc0333d8d4aae1-1\xgboost\xgboost-ci-windows\src\learner.cc:740:

Parameters: { "use_label_encoder" } are not used.

warnings.warn(smsg, UserWarning)

XGBoost kaydedildi: ../trained_models/XGBoost.pkl

XGBoost Accuracy: 0.8056

	precision	recall	f1-score	support
0	0.89	0.88	0.88	83
1	0.82	0.75	0.78	48
2	0.67	0.73	0.70	49
accuracy			0.81	180
macro avg	0.79	0.79	0.79	180
weighted avg	0.81	0.81	0.81	180

MLP Classifier eğitiliyor...

MLP Classifier kaydedildi: ../trained_models/MLP_Classifier.pkl

MLP Classifier Accuracy: 0.5611

	precision	recall	f1-score	support
0	0.71	0.64	0.67	83
1	0.45	0.52	0.48	48

2	0.47	0.47	0.47	49
accuracy			0.56	180
macro avg	0.54	0.54	0.54	180
weighted avg	0.57	0.56	0.57	180

AdaBoost eğitiliyor...

AdaBoost kaydedildi: ../trained_models/AdaBoost.pkl

AdaBoost Accuracy: 0.7278

	precision	recall	f1-score	support
0	0.88	0.80	0.84	83
1	0.88	0.46	0.60	48
2	0.54	0.88	0.67	49

accuracy			0.73	180
macro avg	0.77	0.71	0.70	180
weighted avg	0.79	0.73	0.73	180

Ridge Classifier eğitiliyor...

Ridge Classifier kaydedildi: ../trained_models/Ridge_Classifier.pkl

Ridge Classifier Accuracy: 0.7944

	precision	recall	f1-score	support
0	0.88	0.88	0.88	83
1	0.80	0.67	0.73	48
2	0.67	0.78	0.72	49

accuracy			0.79	180
macro avg	0.78	0.77	0.77	180
weighted avg	0.80	0.79	0.79	180

KNeighbors eğitiliyor...

KNeighbors kaydedildi: ../trained_models/KNeighbors.pkl

KNeighbors Accuracy: 0.4833

	precision	recall	f1-score	support
0	0.59	0.72	0.65	83
1	0.38	0.31	0.34	48
2	0.31	0.24	0.27	49

accuracy			0.48	180
macro avg	0.43	0.43	0.42	180
weighted avg	0.46	0.48	0.47	180

Gaussian NB eğitiliyor...

Gaussian NB kaydedildi: ../trained_models/Gaussian_NB.pkl

Gaussian NB Accuracy: 0.6000				
	precision	recall	f1-score	support
0	0.65	0.77	0.71	83
1	0.49	0.42	0.45	48
2	0.59	0.49	0.53	49
accuracy			0.60	180
macro avg	0.58	0.56	0.56	180
weighted avg	0.59	0.60	0.59	180

En iyi model: Gradient Boosting (Accuracy: 0.8167)

```
# Sonuçları DataFrame olarak göster
results_df = pd.DataFrame(results, columns=["Model", "Test Accuracy"])
print("\nModel Performances:")
print(results_df.sort_values(by="Test Accuracy", ascending=False))
```

Model Performances:

	Model	Test Accuracy
3	Gradient Boosting	0.816667
4	XGBoost	0.805556
7	Ridge Classifier	0.794444
2	Random Forest	0.755556
6	AdaBoost	0.727778
0	Logistic Regression	0.711111
9	Gaussian NB	0.600000
1	SVC	0.594444
5	MLP Classifier	0.561111
8	KNeighbors	0.483333

- En iyi sonucu Gradient Boosting verdiği için bu model ile devam edeceğim ve bu modeli geliştirmek için Hiperparametre Optimizasyonu ve Cross-Validation işlemleri yapacağım
- Hiperparametre Optimizasyonu: Grid Search veya Bayesian Optimization yöntemleriyle hiperparametre optimizasyonu yapılacak.
- Cross-Validation: Modelin genelleme performansını artırmak için cross-validation yöntemleri kullanılacak.

```
#!pip install scikit-optimize

from skopt import BayesSearchCV
from skopt.space import Real, Integer

# Model
gb_model = GradientBoostingClassifier()

# Hiperparametre aralığı (Bayesian Search)
param_space = {
```

```

    'n_estimators': Integer(50, 500), # Ağaç sayısı
    'learning_rate': Real(0.01, 0.2, prior='log-uniform'), # Öğrenme
orani
    'max_depth': Integer(3, 10), # Ağaç derinliği
    'subsample': Real(0.5, 1.0), # Rastgele örnekleme oranı
}

# Bayesian Search
bayes_search = BayesSearchCV(
    gb_model,
    param_space,
    n_iter=10, # Kaç farklı kombinasyon denenecek, çok zaman aldığı
için 10'a indirdim
    cv=StratifiedKFold(n_splits=5, shuffle=True, random_state=42),
    scoring='accuracy',
    n_jobs=-1,
    verbose=2
)

# Modeli eğit
bayes_search.fit(X_train_rfe, y_train_encoded)

Fitting 5 folds for each of 1 candidates, totalling 5 fits
Fitting 5 folds for each of 1 candidates, totalling 5 fits
Fitting 5 folds for each of 1 candidates, totalling 5 fits
Fitting 5 folds for each of 1 candidates, totalling 5 fits
Fitting 5 folds for each of 1 candidates, totalling 5 fits
Fitting 5 folds for each of 1 candidates, totalling 5 fits
Fitting 5 folds for each of 1 candidates, totalling 5 fits
Fitting 5 folds for each of 1 candidates, totalling 5 fits
Fitting 5 folds for each of 1 candidates, totalling 5 fits
Fitting 5 folds for each of 1 candidates, totalling 5 fits

BayesSearchCV(cv=StratifiedKFold(n_splits=5, random_state=42,
shuffle=True),
              estimator=GradientBoostingClassifier(), n_iter=10,
n_jobs=-1,
              scoring='accuracy',
              search_spaces={'learning_rate': Real(low=0.01, high=0.2,
prior='log-uniform', transform='normalize'),
                             'max_depth': Integer(low=3, high=10,
prior='uniform', transform='normalize'),
                             'n_estimators': Integer(low=50, high=500,
prior='uniform', transform='normalize'),
                             'subsample': Real(low=0.5, high=1.0,
prior='uniform', transform='normalize')}}),
              verbose=2)

# En iyi modeli kaydet
best_model = bayes_search.best_estimator_

```



```

joblib.dump(best_model,
"../trained_models/Optimized_Gradient_Boosting.pkl")

# En iyi hiperparametreleri yazdır
print("En iyi parametreler:", bayes_search.best_params_)
print("En iyi skor:", bayes_search.best_score_)

En iyi parametreler: OrderedDict([('learning_rate',
0.07339338249347742), ('max_depth', 7), ('n_estimators', 312),
('subsample', 0.5058257082534684)])
En iyi skor: 0.8125

from sklearn.model_selection import cross_val_score

# En iyi modeli yükle
best_model =
joblib.load("../trained_models/Optimized_Gradient_Boosting.pkl")
# Cross-Validation ile performansı ölç
cv_scores = cross_val_score(best_model, X_train_rfe, y_train_encoded,
cv=5, scoring='accuracy')

print("Cross-validation skorları:", cv_scores)
print("Ortalama doğruluk:", cv_scores.mean())

KeyboardInterrupt

```

Sektörel Benzerlik Analizi

```

from sklearn.pipeline import Pipeline
from sklearn.preprocessing import FunctionTransformer
import tsfresh
from tsfresh.feature_extraction import EfficientFCParameters
import joblib # Modeli yüklemek için

# --- 1. Veri İşleme Fonksiyonları ---
def preprocess_open_values(df):
    """ Open değerlerini işleyip log dönüşümü uygular ve 2005'ten
    itibaren filtreler. """
    df_data = yf.download(df, start='2005-01-01')

    df_open_data = df_data['Open'] # Sadece open verisini al
    df_open_data = df_open_data.ffill().fillna(0) # İlk ffill, sonra
    bütün boş değerleri 0 ile doldur
    df_open_data = df_open_data.resample('M').first() # Günlük
    verileri aylığa çevir.

    df_open_data_long =

```

```

df_open_data.reset_index().melt(id_vars='Date', var_name='Ticker',
value_name='Open') # Long türüne çevir

df_open_data_long['Open_LOG'] =
np.log1p(df_open_data_long['Open']) # Open değerlerinin, Log1/y
değerini al
return df_open_data_long[['Date', 'Ticker', 'Open_LOG']]

# --- 2. Özellik Çıkarma Fonksiyonu ---
def extract_features(df):
    """ Open_LOG üzerinden özellik çıkarır ve seçili olanları
döndürür. """
    features = tsfresh.extract_features(
        df,
        column_id='Ticker',
        column_sort='Date',
        column_value='Open_LOG',
        default_fc_parameters=EfficientFCParameters()
    )

    return features[selected_features_rfe]

# --- 3. Pipeline Tanımlama ---
data_pipeline = Pipeline([
    ('preprocessing', FunctionTransformer(preprocess_open_values)), #
Open işlemleri
    ('feature_extraction', FunctionTransformer(extract_features)), #
Tsfresh özellik çıkarımı
])

# --- 4. Model Yükleme ---
#mlp_model = joblib.load("../trained_models/Gradient_Boosting.pkl") #
Eğittiğin MLP modelini yükle
optimized_gradient_boost_model =
joblib.load("../trained_models/Optimized_Gradient_Boosting.pkl")

def predict_sector(df):
    """ İşlenmiş veriyi modele sokar ve sektöre olan olasılıklarını
döndürür. """
    X_processed = data_pipeline.transform(df)
    probabilities =
optimized_gradient_boost_model.predict_proba(X_processed)[0] #
Olasılıkları al

    sector_mapping = {0: 'Financials', 1: 'Healthcare', 2:
'Technology'}

    # Yuvarlanmış olasılıkları bir sözlük olarak döndür
    sector_probabilities = {sector_mapping[i]: round(prob, 4) for i,
prob in enumerate(probabilities)}

```

```

    return sector_probabilities

# --- 6. Kullanım ---
# Örnek olarak seçilen endüstri şirketi verisi (Industrials, Materials vs.)
df_real_estate_companies = pd.read_csv("../data/stock_sectors/real-estate.csv") # Örnek dosya (inşaat şirketleri)
df_materials_companies = pd.read_csv("../data/stock_sectors/materials.csv")
df_industrials_companies = pd.read_csv("../data/stock_sectors/industrials.csv")
df_energy_companies = pd.read_csv("../data/stock_sectors/energy.csv")

# Şirket sembollerini al
real_estate_tickers = df_real_estate_companies['Symbol'].dropna().tolist()
materials_tickers = df_materials_companies['Symbol'].dropna().tolist()
industrials_tickers = df_industrials_companies['Symbol'].dropna().tolist()
energy_tickers = df_energy_companies['Symbol'].dropna().tolist()

# Şirket isimlerini al (varsa)
real_estate_names = df_real_estate_companies['Company Name'].dropna().tolist()
materials_names = df_materials_companies['Company Name'].dropna().tolist()
industrials_names = df_industrials_companies['Company Name'].dropna().tolist()
energy_names = df_energy_companies['Company Name'].dropna().tolist()

# Sektörleri içeren bir sözlük oluştur
# Rastgele şirketler için bu kısmı çalıştırmak yeterlidir.
sectors = {
    "Real Estate": (real_estate_tickers, real_estate_names),
    "Materials": (materials_tickers, materials_names),
    "Industrials": (industrials_tickers, industrials_names),
    "Energy": (energy_tickers, energy_names)
}

# Rastgele bir sektör seç
selected_sector = random.choice(list(sectors.keys()))
selected_tickers, selected_names = sectors[selected_sector]

# Seçilen sektörden rastgele bir şirket seç
random_index = random.randint(0, len(selected_tickers) - 1)
selected_company_ticker = selected_tickers[random_index]
selected_company_name = selected_names[random_index] if selected_names
else "Unknown"

```

```
# --- Sonuçları Yazdır ---
print(f"Seçilen Şirket: {selected_company_name}
({selected_company_ticker})")
print(f"Şirketin Ait Olduğu Endüstri: {selected_sector}")

Seçilen Şirket: Hess Midstream LP (HESM)
Şirketin Ait Olduğu Endüstri: Energy


# Model tahmini yap
predicted_sector = predict_sector(df_selected_company_ticker_random)

[*****100%*****] 1 of 1 completed
Feature Extraction: 100%[ ] 1/1 [00:06<00:00, 6.12s/it]
D:\Anaconda\Lib\site-packages\sklearn\base.py:457: UserWarning: X has
feature names, but GradientBoostingClassifier was fitted without
feature names
  warnings.warn(

# --- Sonucu Görselleştir ---
# Sözlükten etiketler ve değerler ayrılıyor
labels = list(predicted_sector.keys())
sizes = list(predicted_sector.values())

# Pasta grafiğini oluştur
plt.figure(figsize=(6, 6))
plt.pie(sizes, labels=labels, autopct='%1.1f%%', startangle=140)
plt.title(f"{selected_company_name} ({selected_company_ticker}) -
Sektör Benzerliği")
plt.axis('equal') # Pasta grafiğinin dairesel görünmesini sağlar
plt.show()
```

Hess Midstream LP (HESM) - Sektör Benzerliği



Finans Sağlık ya da Teknoloji şirketleri sonuçları:

```
df_healthcare_companies =  
pd.read_csv("../data/stock_sectors/healthcare.csv")  
healthcare_tickers =  
df_healthcare_companies['Symbol'].dropna().tolist()  
healthcare_name = df_healthcare_companies['Company  
Name'].dropna().tolist()  
  
random_healthcare_company = healthcare_tickers[0]  
random_healthcare_company  
'LLY'  
  
# Model tahmini yap  
predicted_sector = predict_sector(random_healthcare_company)  
  
[*****100%*****] 1 of 1 completed  
Feature Extraction: 100%|██████████| 1/1 [00:06<00:00, 6.37s/it]  
D:\Anaconda\Lib\site-packages\sklearn\base.py:457: UserWarning: X has  
feature names, but GradientBoostingClassifier was fitted without
```

```


feature names
warnings.warn(

# --- Sonucu Görselleştir ---
# Sözlükten etiketler ve değerler ayrılıyor
labels = list(predicted_sector.keys())
sizes = list(predicted_sector.values())

# Pasta grafiğini oluştur
plt.figure(figsize=(6, 6))
plt.pie(sizes, labels=labels, autopct='%1.1f%%', startangle=140)
plt.title(f"{selected_company_name} ({selected_company_ticker}) -
Sektör Benzerliği")
plt.axis('equal') # Pasta grafiğinin dairesel görünmesini sağlar
plt.show()

```

Hess Midstream LP (HESM) - Sektör Benzerliği



ÖNEMLİ NOT

- Hocam bazen rastgele seçilen şirket verilerinde yetersiz data bulunduğu için tsfresh kütüphanesi öznitelik çıkarırken boş sütunlar çıkarabiliyor
- Bu nedenle model boş sütun değerleriyle çalışamadığı için hata veriyor
- Eğer **model NaN değerleriyle çalışamaz** gibi bir hata alırsanız başka bir şirket seçmeniz gerekiyor